Datenstrukturen und effiziente Algorithmen

Markus Vieth, David Klopp, Christian Stricker

18. Dezember 2015

Inhaltsverzeichnis

I.	Sortieren
1.	Vorlesung 1
	1.1. Bubblesort
	1.1.1. Pseudocode
	1.1.2. Laufzeitanalyse
	1.2. Heapsort
	1.2.1. Heap-Eigenschaft
2.	Vorlesung 2
	2.0.1. Pseudocode
	2.0.2. Korrektheitsbetrachtung
	2.0.3. Laufzeitanalyse
3	Vorlesung 11
٠.	3.1. AVL-Bäume von Adelson-Velskii and Landis
	3.1.1. AVL-Eigenschaft:
	3.2. Rotationen
	3.3. Pseudo-Code
1	Vorlaging 12
4.	Vorlesung 12
	4.1. (a,b)-Suchbäume
	4.1.1. Aufspaltung bei Einfügen
	4.1.2. Verschmelzen von Knoten beim Löschen
	4.2. Amortisierte Analyse
	4.2.1. Bankkonto-Methode
5.	Vorlesung 13
	5.1. Hashing
	5.1.1. Universelles Hashing
6.	Vorlesung 14
	6.0.1. Definition
	6.0.2. Beispiel
	6.0.3. Abschätzung nach oben
	6.1. Perfektes Hashing
	6.1.1. Definition
	6.1.2. Nachteil
7.	Vorlesung 15
II.	Graphen-Algorithmen 7.0.1. Einführung
	1.0.1. Emitumung

	7.0.2. BFS (Breadth-First Search) Breitensuche	25
8.	Vorlesung 16	27
	8.1. Kürzeste Wege Algorithmen	32
		32
9.	Vorlesung 17	34
	9.0.1. Vorläufige Laufzeitanalyse von Dijkstra	35
	9.1. Bellman-Ford-Algorithmus	35
	9.1.1. Pseudocode	36
		36
	9.1.3. Korrektheitsbeweis: Bellman-Ford	36
	9.1.4. Induktionsschritt: $i \to i+1$	36
10). Vorlesung 18	37
		37
	10.1.1. Laufzeit zur Berechnung von $D^{(n)}$	38
		38
	10.2.1. Korrektheitsbeweis:	38
	10.2.2. Beweis der Invariante durch Induktion nach k	39

Teil I.

Sortieren

1.1. Bubblesort

1.1.1. Pseudocode

```
void bubblesort (int[] a) {
  int n = a.length;
  for (int i = 1; i < n; i++) {
    for (int j = 0; j < n-i; j++) {
      if (a[j] < a[j+1])
        swap (a, j, j+1);
    }
}</pre>
```

Schleifen-Invariante: Nach dem Ablauf der i-ten Phase gilt:

Die Feldpositionen n-i,...,n-i enthalten die korrekt sortierten Feldelemente

Beweis durch Induktion nach i $\stackrel{i=n-1}{\Longrightarrow}$ Sortierung am Ende korrekt.

1.1.2. Laufzeitanalyse

```
1. Phase n-1
2. Phase n-1
3. Phase n-1
3. Phase n-1
\vdots
i. Phase n-1
\vdots
(n-1). Phase n-1
1+2+3+\ldots+(n+1)
```

$$T(n) = \sum_{i=1}^{n-1} i = \frac{n(n-1)}{2} \in O(n^2)$$

n	T_{real}
2^{10}	8ms
2^{11}	$11 \mathrm{ms}$
2^{12}	$26 \mathrm{ms}$
:	
2^{16}	$5,\!819s$
2^{17}	23,381s
÷	
2^{20}	16min
:	
2^{26}	52d

$$T_{real}(n) \approx cn^2 \ c \approx 10^{-6}$$

1.2. Heapsort

z.B. 21 6 4 7 12 5 3 11 14 17 19 8 9 10 42

Skizze

1.2.1. Heap-Eigenschaft

Heapsort (Fortsetzung)

2.0.1. Pseudocode

```
heapify ( int[] a, int i, int n) {
                                //linkes Kind von i existiert
  while (2i + 1 < n) {
    int j = 2i + 1;
    if (2i +2 < n)
                                //rechtes Kind von i existiert
      if (a[j] < a[j+1])
       j = j + 1;
                                //j steht für Indes des größten Kindes
    if (a[i] > a[j])
                                //Vater größer als Kind
                                //Abbruch, weil heap bereits erfüllt
     break;
   swap(a,i,j);
                                //Tausch zwischen Vater und Kind
    i = j;
}
```

1. Phase: Bottom-up Strategie zum Heapaufbau

```
for ( int i = n/2; i \ge 0; i--)
heapify(a, i, n);
```

2. Phase: Sortierphase

```
for ( int i = n-1; i \ge 0; i--) { swap(a,0,i); heapify(a,0,i);
```

2.0.2. Korrektheitsbetrachtung

Invariante beim Heapaufbau: Beim Durchlauf der for-Schleife wird die Heapeigenschaft vom unteren Baumlevel bis zur Wurzel hergestellt.

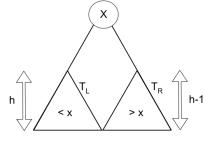
Invariante für Sortierphase: Nach jedem weiteren Durchlauf der for-Schleife findet ein weiteres Element am Feldende seinen "richtigen Platz".

2.0.3. Laufzeitanalyse

T(n) = Zahl der Elementvergleiche.

Analyse Heapaufbau:

3.1. AVL-Bäume von Adelson-Velskii and Landis



Ziel: Zeige, dass die maximale Tiefe eines AVL-Baums mit
n Knoten ($\hat{=}$ n gespeicherten Schlüsseln) $O(\log(n))$ beträgt.

Abbildung 3.1.

3.1.1. AVL-Eigenschaft:

 $|h(T_L) - h(T_R)| \le 1$ muss für jeden Knoten des Baums gelten. \Rightarrow Suchzeit $O(\log(n))$ im worst case.

n(h)=minimale Anzahl von Knoten in AVL-Baum der Tiefe h

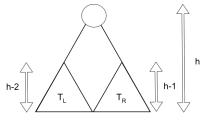


Abbildung 3.2.

$$n(h) \ge 1 + n(h-2) + n(h-1) \text{ mit } n(0) = 0 \text{ und } n(1) = 1$$

$$n \ge f(h)^{\mathrm{I}} = \frac{1}{\sqrt{5}} \cdot (\phi^h - \phi^{-h}) \text{ mit}$$

$$\phi = \frac{1 + \sqrt{5}}{2} \approx 1,61 \dots$$

$$\Rightarrow n \ge c \cdot \phi^h$$

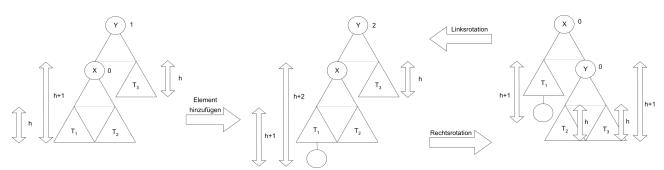
$$\Leftrightarrow h \le \log\left(\frac{n}{c}\right)$$

$$\Rightarrow h \in O(\log n)$$

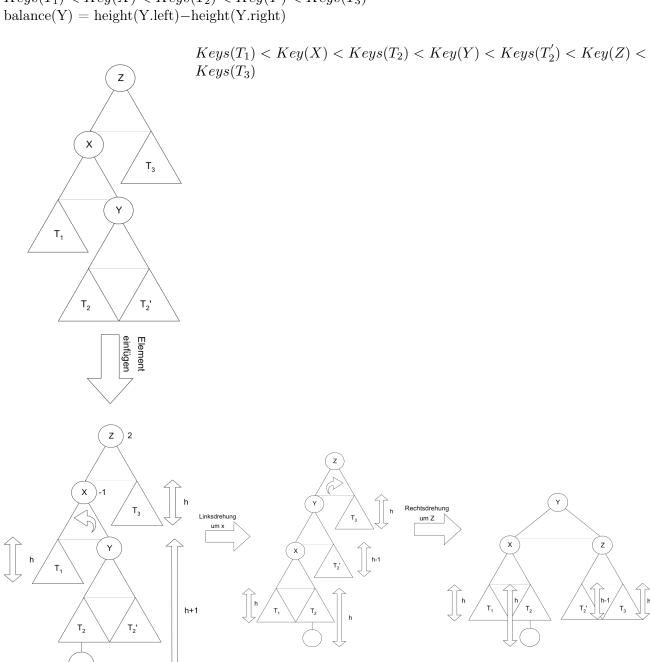
q.e.d.

 $^{^{\}mathrm{I}}f(h)$ meint hierbei die h-te Fibonacci-Zahl

3.2. Rotationen



 $Keys(T_1) < Key(X) < Keys(T_2) < Key(Y) < Keys(T_3)$



3.3. Pseudo-Code

```
class Node {
        int key;
        Node left, right;
        int height;
}
int height(Node node) {
        if (node = null) return 0;
        return height;
}
Node rotateRight (Node y) {
        Node x = y.left;
        Node T2 = x.right;
        y.left = T2;
        T2. right = y;
        y.height = 1+max(height(y.left), height(y.right));
        x.height = 1+max(height(x.left), height(x.right));
        return x;
}
Node rotateLeft (Node y) { //analog }
Node insert (Node node, int key) {
        if (node == null) return new Node(key);
        if (key < node.key)
                node.left = insert(node.left, key);
        else
                node.right = insert(node.right, key);
        if (balance(node)>1 && key < node.left.key)
                return rotateRight(node);
        if (balance(node)<-1 & key > node.right.key)
                return rotateLeft (node);
        if (balance(node)>1 && key > node.left.key) {
                node.left = rotateLeft(node.left);
                return rotateRight(node);
        if (balance(node)<-1 && key < node.right.key) {
                node.right = rotateRight(node.right);
                return rotateLeft(node);
        return node;
}
```

Anmerkung: Die Laufzeit des Einfügens bleibt in $O(\text{Baumtiefe}) = O(\log n)$. Nur einer der vier Fälle ist notwendig, um die Balance herzustellen.

4.1. (a,b)-Suchbäume

Blattorientierte Speicherung der Elemente

Innere Knoten haben mindestens a und höchstens b Kinder und tragen entsprechende Schlüsselwerte, um die Suche zu leiten.

Beispiel:

$$h$$
êTiefe $\Rightarrow a^h \le n \le b^h \Rightarrow \log_b n \le h \le \log_a n$

4.1.1. Aufspaltung bei Einfügen

4.1.2. Verschmelzen von Knoten beim Löschen

Aufspalte- und Verschmelze-Operationen können sich von der Blattebene bis zur Wurzel kaskadenartig fortpflanzen. Sie bleiben aber auf den Suchpfad begrenzt.

 \Rightarrow Umbaukosten sind beschränkt durch die Baumtiefe $= O(\log n)$

4.2. Amortisierte Analyse

	000		
	001	Kosten(1) = 1	
	010	=2	
	011	=1	
Beispiel: Binärzähler	100	=3	Kosten der Inkrement-Operation $\hat{=}$ Zahl der Bit-Flips
	101	=1	
	110	=2	
	111	=1	
		$\overline{11}$	

Naive Analyse $2^k = n$

$$1 \cdot \frac{n}{2} + 2 \cdot \frac{n}{4} + 3 \cdot \frac{n}{8} + \dots + k \cdot \frac{n}{2^k} = \frac{n}{2} \sum_{i=1}^k i(\frac{1}{2})^{i-1} = 2^{k+1} - k - 2 = 2n - k - 2$$

Von 0 bis n im Binärsystem zu zählen kostet $\leq 2n$ Bit-Flips

Sprechweise: amortisierte Kosten einer Inkrement-Operation sind 2 Folge von n-Ops kostet 2n

4.2.1. Bankkonto-Methode

$$\operatorname{Konto}(i+1) = \operatorname{Konto}(i) - \operatorname{Kosten}(i) + \operatorname{Einzahlung}(i)$$

$$\sum_{i=1}^n \operatorname{Kosten}(i) = \operatorname{tats\"{a}chliche} \operatorname{Gesamtkosten} = \sum_{i=1}^n (\operatorname{Einzahlung}(i) + \operatorname{Konto}(i - \operatorname{Konto}(i+1))$$

$$= \sum_{i=1}^{n} \operatorname{Einzahlung}(i) + \operatorname{Konto}(1) - \operatorname{Konto}(n+1)$$

000	
001€	Kosten(1) = 1
01€0	=2
$01 \in 1 \in$	=1
1€00	=3
$1 \in 01 \in$	=1
$1 \in 1 \in 0$	=2
$1 \in 1 \in 1 \in$	=1
	$\overline{11}$

Kontoführungsschema: für Binärzähler

1€ pro 1 in der Binärdarstellung

Jeder Übergang $1 \in \to 0$ kann dann mit dem entsprechenden Euro Betrag auf dieser 1 bezahlt werden. Es gibt pro Inkrement Operation nur einen $0 \to 1$ Übergang

2 € Einzahlung für jede Inc-Operation reichen aus um:

- 1. diesen $0 \to 1$ Übergang zu bezahlen
- 2. die neu entstandene $1_{\mbox{\ensuremath{\in}}}$ mit einem Euro zu besparen.

$$GK = 2(2^k - 1) + 0^I - k^{II} = 2n - k - 2$$

^IZählerstand(000)

 $^{^{\}text{II}}$ Zählerstand $(\overbrace{111\dots 1})$

Satz: Ausgehend von einem <u>leeren</u> 2-5-Baum betrachten wir die Rebalancierungskosten C (Split- und Fusionsoperationen) für eine Folge von m Einfüge- oder Löschoperationen. Dann gilt: $C \in O(m)$ d.h. Amortisierte Kosten der Split- und Fusionsopeartionen sind konstant.

! Dies bezieht sich nicht auf die Suchkosten, die in $O(\log n)$ liegen.

Beweisidee:

Kontoführung:	1	2	3	4	5	6
Nontolullulig.	2€	1€	0€	0€	1€	2€

regelmäßige Einzahlung: 1€

Durch eine Einfüge- oder Löschoperation steigt oder fällt der Knotengrad des direkt betroffenen Knotens um höchstens $1. \Rightarrow 1 \in$ Einzahlung reicht zur Aufrechterhaltung dieses Sparplanes.

Jetzt Beseitigung der temporären 1- und 6-Knoten:

Ein 6-Knoten nutzt $1 \in$ um seinen Split zu bezahlen. Die beiden neu entstehenden 3-Knoten benötigen kein Kapital. Der Vaterknoten des gesplitteten 6-Knotens benötigt ggf. den zweiten verfügbaren \in . Analoge Betrachtung für Fusion eines temp. 1-Knotens.

5.1. Hashing

 $U \subseteq \mathbb{N}$ z.B. 64-Bit-Integer

n = Zahl dr zu verwaltenden Schlüssel

Hashfunktion h:

$$h: U \rightarrow [0, \ldots, m-1]$$

z.B.
$$k \mapsto k \mod m$$

Einfache Annahme: (einfaches uniformes Hashing)

$$\forall k_i, k_j \in U : Pr(h(k_i) = h(k_j)) = \frac{1}{m}$$

Analyse der Laufzeit zum Einfügen eines neuen Elementes k

- h(k) berechnen $\longrightarrow O(1)$
- Einfügen am Listenanfang in Fach h(k). $\longrightarrow O(1)$

Analyse der Suchzeit für einen Schlüssel k

- $h(k) \longrightarrow O(1)$
- Listenlänge zum Fach h(k) sei $n_{h(k)}$ also beim Durchlauf der kompletten Liste $\longrightarrow O(n_{h(k)})$

$$E(n_{h(k)}) = \frac{n}{m} = \alpha^{\mathrm{I}}$$

Suchzeit(Einfügen) $\in O(1 + \alpha)$

Laufzeit beim Löschen von Schlüssel k

- $h(k) \longrightarrow O(1)$
- Durchlaufen der Liste $\longrightarrow 0(n_{h(k)})$
- Löschen durch "Pointer-Umbiegen" $\longrightarrow O(1)$

5.1.1. Universelles Hashing

Idee Arbeite nicht mit einer festen Hashfunktionm sondern wähle am Anfang eine zufällige Hashfunktion aus einer Klasse von Hashfunktionen aus.

z.B.

$$h_{a,b}(k) = ((a \cdot k + b) mod p) mod m$$

p sei eine hinreichend große Primzahl $0 < a < p, 0 \leq b < p$

$$\mathcal{H}_{p,m} = \{ h_{a,b}(k) | 0 < a < p, \ 0 \le b < p \}$$

$$|\mathcal{H}_{p,m}| = p(p-1)$$

Definition \mathcal{H} heißt universell $\Leftrightarrow \ \forall \ k,l \in U: \ Pr(h(k)=h(l)) \leq \frac{1}{m}$

^IBelegungsfaktor

Suchzeit

$$\mathcal{X}_{k,l} = \begin{cases} 1 & \text{für } h(k) = h(l) \\ 0 & \text{sonst} \end{cases}$$

$$E(n_{h(k)}) = E\left(\sum_{l \in T, l \neq k}\right) = \sum_{l \in T, l \neq k} E(X_{k,l}) = \sum_{l \in T, l \neq k} Pr(h(k) = h(l)) = \sum_{l \in T, l \neq k} \frac{1}{m} = \frac{n-1}{m} = \alpha$$

Universelles Hashing (Fortsetzung)

Könnte ein boshafter Mitspieler
n Schlüssel bei gegebener fester Hashfunktion wählen, so würde er solche wählen, die auf den gleichen Slot unter gegebener Hashfunktion abgebildet werden. \leadsto Durchschnittliche Ablaufzeit von O(n)

Idee zufällige Wahl der Hashfunktion aus einer Familie von Funktionen derart, dass die Wahl unabhängig von den zu speichernden Schlüssel ist (universelles Hashing).

6.0.1. Definition

Sei \mathcal{H} eine endliche Menge von Hashfunktionen, welche ein gegebenes Universum U von Schlüsseln auf $\{0,\ldots,m-1\}$ abbildet. Sie heißt universell, wenn für jedes Paar von Schlüsseln $k,l\in U$ $l\neq k$ die Anzahl der Hashfunktionen $h\in\mathcal{H}$ mit h(l)=h(k) höchstens $\frac{|\mathcal{H}|}{m}$. Anders: Für ein zufälliges $h\in\mathcal{H}$ beträgt die Wahrscheinlichkeit, dass zwei unterschiedliche Schlüssel k,l kollidieren nicht mehr als $\frac{1}{m}$ ist.

6.0.2. Beispiel

p Primzahl, so groß, dass alle möglichen Schlüssel $k \in U$ im $0, \ldots, p-1$ liegen. $\mathbb{Z}/p\mathbb{Z}$ bezeichnet den Restklassenring mod p (weil p prim, ist $\mathbb{Z}/p\mathbb{Z}$ ein Körper). $\mathbb{Z}/p\mathbb{Z}^*$ ist die Einheitengruppe.

Annahme: Die Menge der Schlüssel im Universum U ist größer als die Anzahl der Slots in der Hashtabelle. Für $a \in \mathbb{Z}/p\mathbb{Z}^*$ und $b \in \mathbb{Z}/p\mathbb{Z}$ betrachte:

$$h_{a,b}(k) := (a \cdot k + b \mod p) \mod m \quad (*)$$

Damit ergibt sich die Familie

$$\mathbb{Z}/p\mathbb{Z}^* = \{1, \dots, p-1\} \ \mathbb{Z}/p\mathbb{Z} = \{0, \dots, p-1\} \ \mathcal{H}_{p,m} = \{h_{a,b} | a \in \mathbb{Z}/p\mathbb{Z}^*, b \in \mathbb{Z}/p\mathbb{Z}^{(*)} \ |\mathcal{H}| = p(p-1)\}$$

Satz Die in (*) eingeführte Klasse von Hashfunktionen ist universell.

Beweis Seien k, l Schlüssel auf $\mathbb{Z}/p\mathbb{Z}$ mit $k \neq l$

Für $h_{a,b} \in \mathcal{H}_{p,m}$ betrachten wir

$$r = (a \cdot k + b) \mod p$$

$$s = (a \cdot l + b) \mod p$$

Es ist $r \neq s$

Dazu:

$$r - s = a \cdot (k - l) \mod p \quad (*2)$$

Angenommen r - s = 0

$$0 = a \cdot (k - l) \mod p$$
, aber $a \in \mathbb{Z}/p\mathbb{Z}^* \Rightarrow a \neq 0$ und $k \neq l \Rightarrow k - l \neq 0$

Da pprim ist $\mathbb{Z}/p\mathbb{Z}$ ein Körper \Rightarrow kein Nullteiler $\Rightarrow a\cdot (k-l)\neq 0 \Rightarrow r\neq s$

Daher bilden $h_{a,b} \in \mathcal{H}_{p,m}$ unterschiedliche Schlüssel k, l auf unterschiedliche Elemente ab. ("Auf dem level mod p" gibt es keine Kollisionen).

Aus (*2) folgt:

$$(r-s)(k-l)^{-1} = a \mod p$$

$$r - a \cdot k = b \mod p$$
 Bijektion zwischen (k,l) und (a,b)

Daher ist die Wahrscheinlichkeit, dass zwei Schlüssel $h \neq l$ kollidieren, gerade die Wahrscheinlichkeit, dass $r \equiv s \mod m$, falls $r \neq S$ zufällig gewählt (aus $\mathbb{Z}/p\mathbb{Z}$).

Für gegebenes r gibt es unter den übrigen p-1 Werten für s höchstens $\lceil \frac{p-1}{m} \rceil \leq \lceil \frac{p}{m} \rceil - 1$ Möglichkeiten, sodass $s \neq r \mod p$ aber $r = s \mod m$

6.0.3. Abschätzung nach oben

$$\lceil \frac{p}{m} \rceil - 1 \leq \frac{(p+m-1)}{m} - 1 = \frac{p-1}{m}$$
Kollisionsmöglichkeiten

Die Wahrscheinlichkeit, dass r und s kollidieren $\mod m$ Kollisionsmöglichkeiten / Gesamtzahl der Werte

$$= \frac{p-1}{m} \cdot \frac{1}{p-1} = \frac{1}{m}$$

 \Rightarrow Für ein Paar von Schlüsseln $k,l\in\mathbb{Z}/p\mathbb{Z}$ mit $k\neq l$

$$P[h_{a,b}(k) = h_{a,b}(l)] \le \frac{1}{m} \Rightarrow \mathcal{H}_{p,m}$$
 universell!

6.1. Perfektes Hashing

Wichtig Menge der Schlüssel ist im Vorhinein bekannt und ändert sich nicht mehr.

Beispiele reserved words bei Programmiersprachen, Dateinamen auf einer CD

6.1.1. Definition

Eine Hashmethode heißt perfektes Hashing, falls O(1) Speicherzugriffe benötigt werden, um die Suche nach einem Element durchzuführen.

Idee Zweistufiges Hashing mit universellen Hashfunktionen.

- 1. Schritt n Schlüssel, m Slots durch Verwendung der Hashfunktion h, welche aus einer Familie universeller Hashfunktionen stammt.
- 2. Schritt Statt einer Linkedlist im Slot anzulegen, benutzen wir eine kleine zweite Hashtabelle S_j mit Hashfunktion h_j

Bild Schlüssel $k = \{10, 22, 37, 49, 52, 60, 72, 75\}$ Äußere Hashfunktion $h(k) = ((a \cdot b) \mod p) \mod m$

$$a = 3, b = 42, p = 101, m = 9$$

$$h(10) = \underbrace{(3 \cdot 10 + 42 \mod 101)}_{=72} \mod 9 = 0$$

Um zu garantieren, dass keine Kollision auf der zweiten Ebene auftreten, lassen wir die Größe von S_i

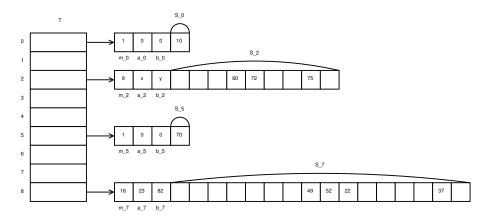


Abbildung 6.1.: Perfekte Hashtabelle

gerade n_j^2 sein $(n_j \neq \#Schlüssel \mapsto jSlot)$.

Wir verwenden für die Hashfunktion der ersten Ebene eine Funktion aus $\mathcal{H}_{p,m}$. Schlüssel die im j-ten Slot werden in der sekundären Hashtabelle S_j der Größe m_j mittels h_j gehasht. $h_j \in \mathcal{H}_{p,m}$

Wir zeigen: 2 Dinge:

- 1. Wie versichern wir, dass die zweite Hashfunktion keine Kollision hat.
- 2. Der erwartete Speicherbedarf ist O(n)

zu 1.

Satz Beim Speichern von n Schlüsseln in einer Hashtabelle der Größe $m=n^2$ ist die Wahrscheinlichkeit, dass eine Kollision auftritt $<\frac{1}{2}$

Beweis: Es gibt $\binom{n}{2}$ mögliche Paare, die kollidieren können. Jedes kollidiert mit der Wahrscheinlichkeit $\leq \frac{1}{m}$, falls $h \in \mathcal{H}$ zufällig gewählt wurde.

Sei X eine zufallsvariable(ZV), X zählt Kollisionen:

Für $m = n^2$ ist die erwartete Zahl der Kollisionen:

$$E[X] = \binom{n}{2} \cdot \frac{1}{m} = \binom{n}{2} \cdot \frac{1}{n^2} = \frac{n!}{2!(n-2)!n^2} = \frac{(n-1)}{2n} \le \frac{1}{2}$$

Anwenden der Markow-Ungleichung (a=1):

$$P[X \ge 1] \le \frac{E[X]}{1} = \frac{1}{2} \Rightarrow$$
 Wahrscheinlichkeit für irgendeine Kollision ist $< \frac{1}{2}$

q.e.d

6.1.2. Nachteil

Für große n ist $m = n^2$ nicht haltbar!

zu 2. Wenn die Größe der primären Hashtabelle m=n ist, dann ist der Platzverbrauch in $O(n) \curvearrowright$ Betrachte Platzverbrauch der sekundären Hashtabellen.

Satz Angenommen wir wollen n Schlüssel in einer Hashtabelle der Größe m=n mit Hashfunktion $h \in \mathcal{H}$. Dann gilt:

$$E\left[\sum_{j=0}^{m-1} n_j^2\right] < 2n$$

Beweis

Betrachte

$$a^{2} = a + 2 \cdot {a \choose n} = a + 2 \cdot \frac{a^{2} - a}{2} \quad (*3)$$

Betrachte

$$E\left[\sum_{j=0}^{m-1} n_j^2\right] \stackrel{(*3)}{=} E\left[\sum_{j=0}^{m-1} \left(n_j + 2\binom{n_j}{2}\right)\right]$$

$$\stackrel{lini.desEW}{=} E \left[\sum_{j=0}^{m-1} n_j \right] + 2E \left[\sum_{j=0}^{m-1} \binom{n_j}{2} \right] = n + 2E \left[\sum_{j=0}^{m-1} \binom{n_j}{2} \right] \# \text{ der Kollisionen}$$

Da unsere Hashfunktion universell ist, ist die erwartete Zahl dieser Paare:

$$\binom{n}{2}\frac{1}{m}=\frac{n(n-1)}{2m}=\frac{n-1}{2},$$
da $m=n$

Somit

$$E\left[\sum_{j=0}^{m-1} n_j^2\right] \le n + 2\frac{n-1}{2} = 2n - 1 < 2n$$

Korollar Speichern wir n Schlüssel in einer Hashtabelle der Größe m=n mit einer zufälligen universellen Hashfunktion und setzen die Größe der Hashtabellen der zweiten Ebene auf $m_j=n_j^2$ für j=0, m=1, so ist der Platzverbrauch des perfekten Hashings weniger als 2n. Die Wahrscheinlichkeit, dass der Platzverbrauch der zweiten Hashtabellen $\geq 4n$ ist, ist $\leq \frac{1}{2}$ ohne Beweis.

Bei n Elementen sollte die Hashtabelle $m=n^2$ groß sein. Für die universellen Hashfunktionen

$$\mathcal{H}_{p,m} = \{h_{a,b}(k) = (a \cdot k + b) \mod p \mod m | 0 < a < p, \ 0 \le b < p\}$$

 $\binom{n}{1}$ Schlüsselpaare (k,l) mit $k \neq l$

$$E(\# \text{Kollisionen}) \leq \binom{n}{2} \cdot \frac{1}{m}^{\text{I}} = \frac{n(n-1)}{2} \cdot \frac{1}{n^2} \leq \frac{1}{2}$$

Idee Zweistufiges Verfahren:

 $\bullet\,$ primäre Hashfunktion für Tabelle der Größe m=n

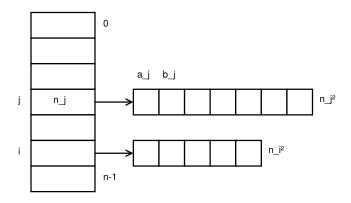


Abbildung 7.1.: Perfektes Hashing

 $^{^{\}rm I}$ Universalität von ${\mathcal H}$

Teil II. Graphen-Algorithmen

7.0.1. Einführung

 $G = (V, E) \quad V \text{ vertices, } E \text{ edges} \quad E \subseteq V \times V$

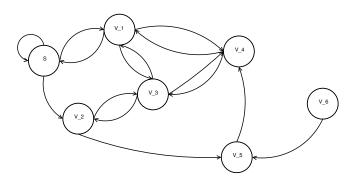


Abbildung 7.2.: Gerichteter Graph

Planare Graphen können ohne Überkreuzung der Kanten in die Ebene eingebettet werden.

Eulerische Polyederformel

$$|V| + |F| = |E| + 2$$

$$8+6=12+2$$

Es gilt:

$$2 \cdot |E| \ge 3 \cdot |F|$$

#gerichtete Kanten =
$$2 \cdot |E| = \sum_{i=1}^{|F|} \# \text{Kanten}(f_i)^{\text{II}} \ge 3 \cdot |F|$$

$$|F| \leq \frac{2}{3}|E|, \quad |V| + |F| = |E| + 2 \leq |V| + \frac{2}{3}|E| \Rightarrow \frac{1}{3}|E| + 2 \leq |V|$$

$$\Rightarrow |E| \le 3 \cdot |V| - 6$$

Abbildung 7.4.: Placehol-

Abbildung 7.3.: Würfel

 der

II Jedes f_i hat mindestens 3 Kanten

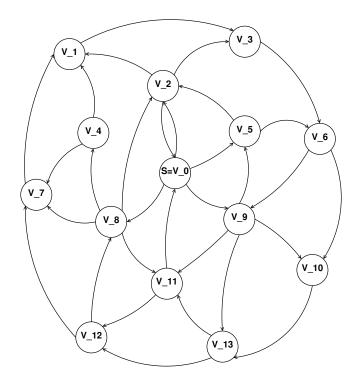


Abbildung 7.5.: Beispiel

Adjazenzmatrix

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	
0	1	0	1	0	0	1	0	0	1	1	0	0	0	0	
1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	
2	1	1	1	1	0	0	0	0	0	0	0	0	0	0	
3	0	0	0	1	0	0	1	0	0	0	0	0	0	0	
4	0	1	0	0	1	0	0	1	0	0	0	0	0	0	
5	0	0	1	0	0	1	1	0	0	0	0	0	0	0	
6	0	0	0	0	0	0	1	0	0	1	1	0	0	0	= A
7	0	1	0	0	0	0	0	1	0	0	0	0	0	0	
8	0	0	1	0	1	0	0	1	1	0	0	0	0	0	
9	0	0	0	0	0	1	0	0	0	1	1	1	0	1	
10	0	0	0	0	0	0	0	0	0	0	1	0	0	1	
11	1	0	0	0	0	0	0	0	0	0	0	1	1	0	
12	0	0	0	0	0	0	0	1	1	0	0	0	1	0	
13	0	0	0	0	0	0	0	0	0	0	0	1	1	1	

$$a \in B^{|V| \times |V|}$$

falls G ungerichtet $\Rightarrow A = A^T$

Adjazenzlisten Repräsentation

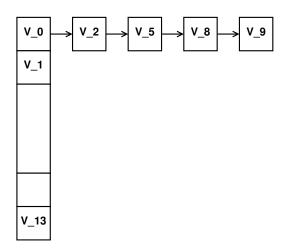


Abbildung 7.6.: Adjazenzliste

Platzbedarf

$$\mathcal{O}(|V| + |E|) = \mathcal{O}\left(|V| + \sum_{i=0}^{|V|-1} \text{outdeg}(v_i)\right)$$

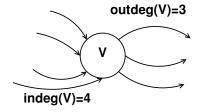


Abbildung 7.7.: indeg und outdeg

7.0.2. BFS (Breadth-First Search) Breitensuche

```
for all (v in V \setminus \{S\}) {
                    // Farbe weiß = unbekannt, grau = bekannt, schwarz = vollkomn
  col[v] = white;
  d[v] = infinity; // Distanz
  pi[v] = NULL; // pi ist Vorgänger
col[s] = grey;
                      // s ist Startknoten
d[s] = 0;
pi[s] = null;
      Queue
                            \operatorname{Stack}
                  vs
     Schlange
                           Stapel
     empty()
      push()
      pop()
      FIFO
                           FILO
First-In-First-Out
                      First-In-First-Out
```

```
Queue Q;
Q.push(s);
while (!Q.empty()) {
    u = Q.pop();
    forall((u,v) in E) {
        if (col[v] == white) {
            col[v] == grey;
            d[v] = d[u]+1;
            pi[v] = u;
            Q.push(v);
        }
    }
    col[u] = black;
}
```

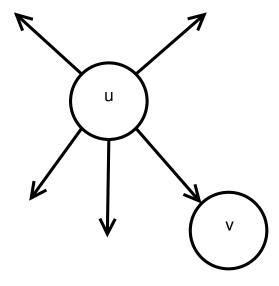


Abbildung 7.8.: Grafik zum Beispielcode

Laufzeit

$$O(|V| + |E|)$$

Begründung: Jeder von s aus erreichbare Knoten wird nur einmal in die Queue aufgenommen und auch ihr entfernt. Für jeden Knoten muss nur einmal seine Adjazenzliste durchlaufen werden.

$$\Rightarrow \mathcal{O}\left(|V| + \sum_{v \in V} \text{outdeg}(v)\right)$$

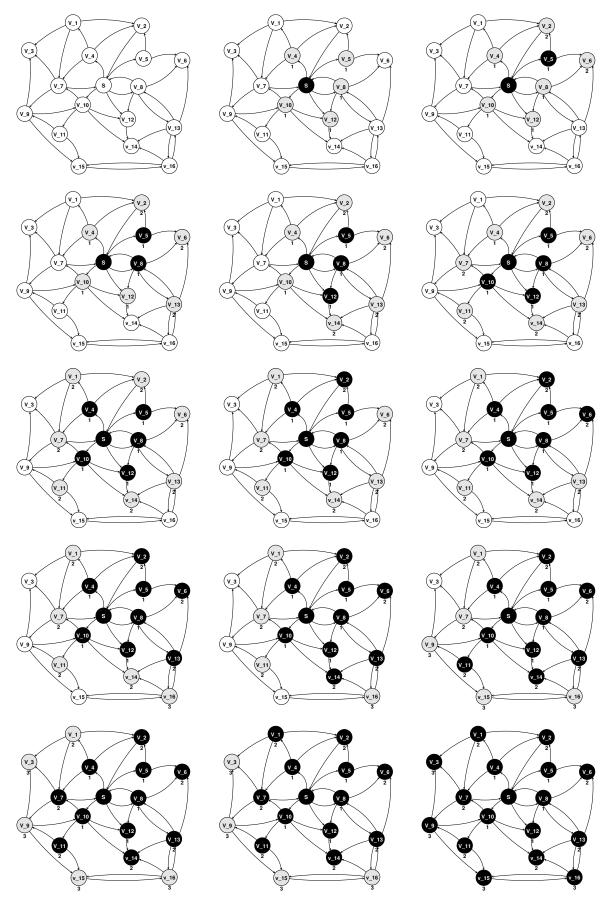


Abbildung 8.1.: Beispiel

Definition: Länge kürzesten Weges

 $\delta(s,v)=$ Länge eines kürzesten Weges vom Startknoten s zum Knoten v. Setze $\delta(s,v)=\infty$, falls v nicht erreichbar von s aus.

Satz: Richtigkeit des Algorithmus

Nach Ablauf von BFS^I gilt

$$\forall v \in V: \ d[v] = \delta(s, v)$$

Lemma 1: Dreiecksungleichung für kürzeste Wege

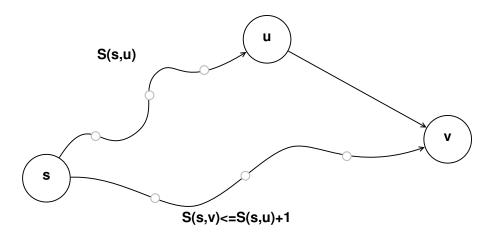


Abbildung 8.2.

Lemma 2

Zu jedem Zeitpunkt im Verlauf von BFS gilt:

$$\forall v \in V : d[v] \ge \delta(s, v)$$

Beweis (induktiv über Zahl der Operationen, die d-Wert verändern)

Induktions-Anfang

$$d[s] = 0\sqrt{}$$

Induktions-Schritt Knoten v wird von u aus neu entdeckt

$$d[u] \ge \delta(s, u)$$

$$d[v] = d[u] + 1 \ge \delta(s, u) + 1 \stackrel{D.U.}{\ge} \delta(s, v)$$

Lemma 3

Sei $Q = (v_1, v_2, \dots, v_k)$ eine Queue, dann gilt stets:

$$d[v_1] \le d[v_2] \le \ldots \le d[v_k] \le d[v_1] + 1$$

 $^{^{\}rm I}{\rm Breiten such e}$

Beweis (induktiv über die Zahl der push- und pop-Operationen)

Induktions-Anfang

$$d[s] = 0\sqrt{}$$

Induktions-Schritt

pop

$$d[v_1] \le d[v_2] \le \dots \le d[v_k] \le d[v_1] + 1 \le d[v_2] + 1$$

push

$$d[u] = d[v_1] \le d[v_2] \le \ldots \le d[v_k] \le d[u] + 1$$

Beachte Kante (u, v) v ist weiß

 $v = v_{k+1}$ wird gepushed

$$d[v_{k+1}] = d[v_1] + 1$$

Zustand von Q nach push

$$d[v_2 \le d[v_3] \le \dots \le d[v_k] \le d[v_1] + 1 = d[v_{k+1}] \ \sqrt{}$$

Satz: Richtigkeit des Algorithmus

Nach Ablauf von BFS^{II} gilt

$$\forall v \in V : d[v] = \delta(s, v)$$

Beweis durch Widerspruch

Sei $v \in V$, so dass $d[v] \neq \delta(s, v)$ am Ende des Algorithmus $\stackrel{Lemma2}{\Longrightarrow} d[v] > \delta(s, V)$

Sei v so gewählt, dass es der erste knoten ist mit der Eigenschaft, dass sein d-Wert flasch gesetzt wird. d.h. Alle d-Werte bis zu diesem Zeitpunkt sind korrekt.

Sei $s \mapsto u' \to v$ ein kürzester Weg s ui v

Betrachte die Situation bei Bearbeitung von u':

1. Fall v ist in diesem Moment schwarz.

$$d[v] > \delta(s, v) = \delta(s; u') + 1 > ^{\mathrm{III}}d[v]$$

2. Fall v ist in diesem Moment weiß.

II Breitensuche

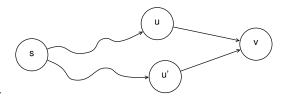
 $^{^{\}mathrm{III}}v$ vor u' aus Q entfernt und Lemma 3.

 $^{^{\}mathrm{IV}}$ wegen Wahl von v;d-Wert von u'muss also korrekt sein

3. Fall v ist grau.

$$d[v] > \delta(s,u') + 1 = d[u'] + 1 \ge d[u] + 1 = d[v]$$

$$d[u] \le d[u'], \text{ weil } u \text{ vor } u' \text{ aus } Q \text{ entfernt } \sharp$$



q.e.d.

Abbildung 8.3.

8.1. Kürzeste Wege Algorithmen

8.1.1. Dijkstra-Algorithmus

$$G = (V, E)$$
 $w : E \to \mathbb{R}_0^+$

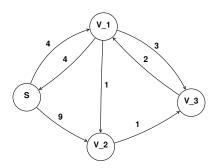


Abbildung 8.4.

Sei
$$p = (s = v_0, v_1, v_2, \dots, v_k)$$



Abbildung 8.5.

$$w(p) = \sum_{i=0}^{k-1} w(v_i, v_{i+1}) = \delta(s, v_k)$$

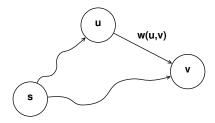


Abbildung 8.6.

$$\delta(s, v) \le \delta(s, U) + w(u, v)$$

$$\begin{array}{lll} relax \, (u\,,v\,,w) & \{ & \\ & i\, f\, (d\, [\, v\,] \, > \, d\, [\, u] + w (\, u\,,v\,) \,\,) & \{ & \\ & d\, [\, v\,] \, = \, d\, [\, u\,] \, + \, w (\, u\,,v\,) \,; \\ & \Pi [\, v\,] \, = \, u\,; & \\ & \} & \\ \} & \\ \end{array}$$

Betrachte Algorithmen zur kürzesten Wege Berechnung, die Distanzwerte nur mit Hilfe dieser relax-Funktion verändern, dann gilt:

$$d[v] \ge \delta(s, v) \quad \forall v \in V$$

Beweis

$$d[v] = d[u] + w(u, v) \stackrel{I.A.}{\geq} \delta(s, u) + w(u, v) \geq \delta(s, v)$$

Induktion über Zahl der reflex-Aufrufe

Dijkstra Algorithmus (Fortsetzung)

$$G = (V, E) \ w : E \to \mathbb{R}^{\geq 0}$$

```
for all (v \in V) {
  d[v] = \infty;
  \Pi[v] = NULL;
d[s] = 0;
S = \emptyset;
PriorityQueue PQ;
for all (v \in V)
  PQ.insert((d[v],v));
while (!PQ.empty()) {
  u = PQ. deleteMin();
  for all (u, v) \in E {
     if (d[v] > d[u] + w(u,v)) {
       d[v] = d[u] + w(u,v);
       \Pi[v] = u;
       PQ.decreaseKey((d[v],v));
  \dot{S} = S \cup \{u\};
```

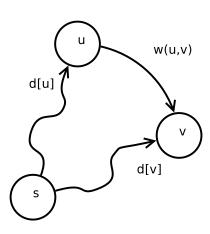


Abbildung 9.1.

Satz: Der Dijkstra Algorithmus berechnet alle d-Werte, so dass nach Ablauf des Algo $\forall v \in V$ gilt: $d[v] = \delta(s, v)$.

Beweis:

Annahme:

$$\exists v \in V: \ d[v] \neq \delta(s, v)$$

$$\stackrel{LemmaRelax}{\Longrightarrow} d[v] > \delta(s, v)$$

Sei v so gewählt, das v der erste Knoten mit der Eigenschaft ist, der mit deleteMin der PQ entnommen wird und nach Relaxation aller von ihm ausgehenden Kanten der Menge S hinzugefügt wird.

Betrachte einen kürzesten Weg $s \leadsto v$

$$d[v] > \delta(s,v) \geq {}^{\mathrm{I}}\delta(s,y) = d[y] = {}^{\mathrm{II}}d[x] + w(x,y) = d[y] \geq {}^{\mathrm{III}}d[v] \quad \sharp$$

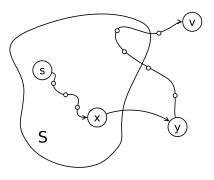


Abbildung 9.2.: Skizze

9.0.1. Vorläufige Laufzeitanalyse von Dijkstra

PQ.insert x |V|PQ.empty x |V|PQ.deleteMin x |V| Mit balanciertem Suchbaum oder mit binärem Heap (siehe Heapsort) PQ.decreaseKey x |E|

können diese Opeartionen alle in Zeit $\mathcal{O}(\log |V|)$ realisiert werden.

 \Rightarrow Gesamtlaufzeit: $\mathcal{O}((|V| + |E|) \log |V|)$

Wir werden später zeigen, dass Laufzeit $\mathcal{O}(|V| \log |V| + |E|)$ möglich ist.

9.1. Bellman-Ford-Algorithmus

$$G = (V, E) \ w : E \to \mathbb{R}$$

Voraussetzung G enthält keine negativen Zyklen

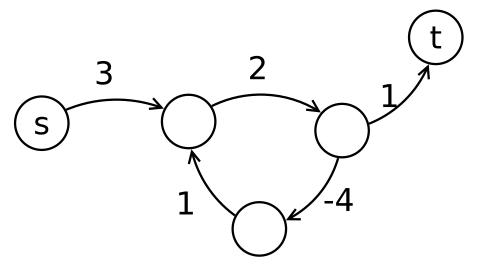


Abbildung 9.3.: Ein verbotener, negativer Zyklus

^Iweil Kantengewichte nicht negativ sein dürfen

 $^{^{\}mathrm{II}}\mathbf{x}$ wurde schon zu S hinzugefügt, hat also Korrekten d-Wert $d[x] = \delta(s,x)$

 $^{^{\}rm III}$ weil v
 vor y aus der PQ entnommen wird.

9.1.1. Pseudocode

```
\begin{array}{l} \mbox{forall} (v \in V) \  \, \{ \\ \mbox{d}[v] = \infty; \\ \mbox{\Pi}[v] = \mbox{NULL}; \\ \} \\ \mbox{d}[s] = 0; \\ \mbox{for} (i = 1; \ i < |V|; \ i++ ) \\ \mbox{forall} ((u,v) \in E) \\ \mbox{if} (\ d[v] > d[u] + w(u,v)) \  \, \{ \\ \mbox{d}[v] = d[u] + w(u,v); \\ \mbox{\Pi}[v] = u; \\ \} \end{array}
```

9.1.2. Laufzeit: Bellman-Ford

$$O(|V| \cdot |E|)$$

9.1.3. Korrektheitsbeweis: Bellman-Ford

Invariante: Nach den i-ten Schleifendurchlauf sind alle Kürzesten Wege korrekt berechnet, die $\leq i$ Kanten benutzen.

Beweis: Induktion über i

Induktionsanfang

i=0 $d[s]=0=\delta(s,s)$, da keine negativen Zyklen vorliegen.

9.1.4. Induktionsschritt: $i \rightarrow i+1$

Betrachte kürzesten Weg mit i + 1 Kanten:

$$s = v_0 \rightarrow v_1 \rightarrow v_2 \rightarrow \ldots \rightarrow v_i \rightarrow v_{i+1}$$

Aufgrund der Induktionsannahme^{IV} gilt: $d[v_i] = \delta(s, v_i)$, weil $s = v_0 \to v_1 \to \ldots \to v_i$ ein kürzester Weg $s \leadsto v_i$ mit i Kanten ist. Da alle Kanten in der inneren Schleife einmal relaxiert werden, trifft dies insbesondere auf die Kante (v_i, v_{i+1}) zu:

$$d[v_{i+1}] = d[v_i] + w(v_i, v_{i+1}) = \delta(s, v_i) + w(v_i, v_{i+1}) = \delta(s, v_{i+1})$$

Frage: Warum folgt aus der Gültigkeit dieser Invariante die Korrektheit des Algo?

Antwort Alle kürzesten Wege benutzen höchstens |V|-1 Kanten, ansonsten hätten sie einen Zyklus mit Gewicht ≥ 0 , den man auch weglassen kann.

```
//Erkennung der Existenz negativer Zyklen for all ((u,v) \in E) if (d[v] > d[u] + w(u,v)) negativer Zyklus
```

^{IV}Die Invariante

10.1. All-Pairs-Shortest Path Algorithmen

Distanz
matrix D für einen Graphen $G=(V,E)\ V=v_1,v_2,\ldots,v_n,\ w:E\mapsto\mathbb{R}$

$$d_{ij} = \begin{cases} 0 & \text{für } i = j \\ w(v_i, v_j) & \text{für } (v_i, v_j) \in E \\ \infty & \text{sonst} \end{cases}$$

$$D = (d_{ij})_{\substack{i=1,\dots,n\\j=1,\dots,n}} \in \mathbb{R}^{n \times n}$$

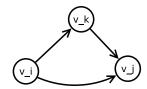


Abbildung 10.1.: Grafik

$$d_{ij}^{(2)} = \min(d_i^{(1)}j, \ \min(d_{ik}^{(1)} + d_k^{(1)}j))$$

$$k=1,\dots,n$$

$$D^{(2)} = D^{(1)} \circ D^{(1)} = \min(d_{ik}^{(1)} + d_k^{(1)}j)$$

Vergleich zu Matrixmultiplikation

$$C = A \circ B$$
 , mit $A, B \in \mathbb{R}^{n \times n}$

$$C_{ij} = \sum_{k=1}^{n} a_{ik} \cdot b_{kj}$$

im Ring $(\mathbb{R}, +, \cdot)$

$$C_{ij} = (A_{ik} + B_{kj})$$

Kommutativgesetz

$$\min(\min(a, b), c) = \min(a, b, c)$$

im "Ring" $(\mathbb{R}, \min, +)$

Distributivgesetz

$$a + \min(b, c) = \min(a + b, a + c)$$

^Ider keiner ist

Assoziativgesetz

$$A \circ (B \circ C) = (A \circ B) \circ C$$

Ziel: $D^{(n)II} = D^{(1)} \circ D^{(1)} \circ \ldots \circ D^{(1)}$

Es gilt: $D^{(n)} = D^{(n+m)}$ für $m \ge 1$

10.1.1. Laufzeit zur Berechnung von $D^{(n)}$

Naiv: $O(n^4)$

$$D^{(2)} = D^{(1)} \circ D^{(1)}$$

$$D^{(4)} = D^{(2)} \circ D^{(2)}$$

$$D^{(8)} = D^{(4)} \circ D^{(4)}$$

:

$$D^{(2^i)} = D^{(2^{i-1})} \circ D^{(2^{i-1})}$$

Schrittzahl i so wählen, dass $2^i \ge n$

sukzessives Quadrieren: $O(n^3 \log n)$

10.2. Floyd-Warshall-Algorithmus

$$\begin{array}{lll} for \ (\ k = 1; \ k \leq n; \ k++) \\ for (\ i = 1; \ i \leq n; \ i++) \\ for \ (\ j = 1; \ j \leq n; \ j++) \\ d[\,i\,][\,j\,] = min(d[\,i\,][\,j\,], \ d[\,i\,][\,k]+d[\,k\,][\,j\,]) \end{array}$$

 $\textbf{Laufzeit} \quad \mathfrak{O}(n^3)$

10.2.1. Korrektheitsbeweis:

Invariante Nach dem k-ten Schleifendurchlauf entspricht d_{ij} der Weglänge eines kürzesten Weges p von v_i nach v_j , wobei nur Zwischenknoten erlaubt sind, mit Index $\leq k$

$$p: v_i \to v_{l_1} \to v_{l_2} \to \ldots \to v_{l_m} \to v_j$$

d.h.
$$1 \le l_1, l_2, \dots, l_m \le k$$

^{II}In der Potenz stehen die Anzahl der betrachteten Kanten. n entspricht allen Kanten

10.2.2. Beweis der Invariante durch Induktion nach k

k=0: Nach der Initialisierung von D, also vor dem 1. Schleifendurchlauf, gilt obige Invariante. $k-1 \to k$:

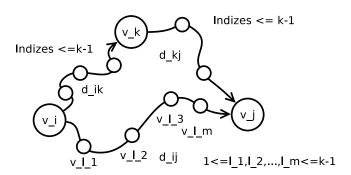


Abbildung 10.2.: Beweis der invariante

Durch die Operation $d_{ij} = \min(d_{ij}, d_{ik} + d_{kj})$ wird die Invariante sichergestellt.

10.3. Naive Lösung des All-Pairs Problems durch |V|-malige Anwendung von Bellman-Ford oder Dijksta-Algorithmus

 $\label{eq:bellman-Ford} \begin{array}{l} \text{Bellman-Ford} \ \ \mathcal{O}(|V|\cdot|V|\cdot|E|) = \mathcal{O}(|V|^2\cdot|E|) \\ \\ \text{Dijksra} \ \ \mathcal{O}(|V|\cdot(|V|\cdot\log|V|+|E|)) = \mathcal{O}(|V|\cdot|E|+|V|^2\cdot\log|V|) \end{array}$