Datenstrukturen und effiziente Algorithmen

Markus Vieth David Klopp Christian Stricker

24. Dezember 2015

Inhaltsverzeichnis

I.	Soi	rtieren		_
1.	Vorle	esung		Ę
	1.1.	Bubble	esort	,
		1.1.1.	Pseudocode	,
		1.1.2.	Laufzeitanalyse	(
	1.2.	Heapso	ort	(
		1.2.1.	Idee	7
2.	Vorle	esung		8
		_	ocode	8
			Phase: Bottom-up Strategie zum Heapaufbau	8
			Phase: Sortierphase	8
	2.2		theitsbetrachtung	8
			itanalyse	(
		2.3.1.	Zusammenhang von n und k	(
		2.3.2.	_	L(
		2.3.3.		L(
				L (
3.	Vorl	esung	1	. 2
	3.1.	Landa	u-Notation	[2
		3.1.1.	O(n)	L2
		3.1.2.	$\Omega(n)$	L2
		3.1.3.	$\Theta(n)$	L2
		3.1.4.	o(n)	L2
		3.1.5.	Notation	13
	3.2.	Merges	sort (Divide and Conquer)	13
		3.2.1.	Pseudo-Code	ť
		3.2.2.	Laufzeitanalyse	<u>L</u> 4
4.	Vorle	esung	1	. 5
				LE
		4.1.1.		L
		4.1.2.		16
		4.1.3.		L (
		4.1.4.		L (
	4.2.			L (
	1.4.	4.2.1.	•	17
		4.2.2.	*	L 7
				18

5.	Vorl	sung 19
	5.1.	Akra-Brazzi
	5.2.	Lineare Rekursionsgleichungen
		5.2.1. Fibonacci-Zahlen
		5.2.2. Methode der erzeugenden Funktionen
		5.2.3. Einschub: Beispiel Reihenentwicklung
		5.2.4. Nullstellen des Nennerpolynoms
		5.2.5. Partialbruchzerlegung
		5.2.6. Lösung
	5.3.	Quicksort (Divide and Conquer)
	0.0.	(21/1de dila conquer)
6.	Vorl	sung 22
		Quicksort
		5.1.1. Pseudo-Code
		3.1.2. Zufallspermutation
		3.1.3. Einschub: Stochastik
		3.1.4. Laufzeitanalyse
	6.2	Median in Linearzeit
	0.2.	
7.	Vorl	Sung 20
		Quicksort
		Quickselect
8.	Vorl	sung 2°
	8.1.	Verallgemeinerung von Akra-Brazzi
	8.2.	Median der Mediane
		8.2.1. Deterministische Variante für k-Select
		8.2.2. Laufzeitanalyse für den worst-case
	8.3.	Untere Schranke für vergleichsbasierte Sortierverfahren
9.	Vorl	sung 30
	9.1.	Vergleichsbasierte Sortieralgorithmen
		9.1.1. Worst-case Laufzeit
		9.1.2. Lemma: Mittlere Tiefe der Blätter in einem Entscheidungsbaum $> \log_2(n)n$. 3
	9.2.	Radix-Sort
		9.2.1. Beispiel:
		9.2.2. Pseudo-Code
	9.3.	Binäre Suchbäume
10	. Vorl	
	10.1.	Binärer Suchbaum
	10.2.	Pseudo-Code
	10.3.	AVL-Bäume
	10.4.	Laufzeitanalyse
11	. Vorl	
	11.1.	AVL-Bäume von Adelson-Velskii and Landis
		11.1.1. AVL-Eigenschaft:
	11.2.	Rotationen
	11.3.	Pseudo-Code

12.	Vorlesung
	12.1. (a,b)-Suchbäume
	12.1.1. Aufspaltung bei Einfügen
	12.1.2. Verschmelzen von Knoten beim Löschen
	12.2. Amortisierte Analyse
	12.2.1. Bankkonto-Methode
13.	Vorlesung
	13.1. Hashing
	13.1.1. Universelles Hashing
14.	Vorlesung
	14.0.1. Definition
	14.0.2. Beispiel
	14.0.3. Abschätzung nach oben
	14.1. Perfektes Hashing
	14.1.1. Definition
	14.1.2. Nachteil
15.	Vorlesung
II.	1 0
	15.0.1. Einführung
	15.0.2. BFS (Breadth-First Search) Breitensuche
16.	Vorlesung
	16.1. Kürzeste Wege Algorithmen
	16.1.1. Dijkstra-Algorithmus
17.	Vorlesung
	17.0.1. Vorläufige Laufzeitanalyse von Dijkstra
	17.1. Bellman-Ford-Algorithmus
	17.1.1. Pseudocode
	17.1.2. Laufzeit: Bellman-Ford
	17.1.3. Korrektheitsbeweis: Bellman-Ford
	17.1.4. Induktionsschritt: $i \to i+1$
18.	Vorlesung
	18.1. All-Pairs-Shortest Path Algorithmen
	18.1.1. Laufzeit zur Berechnung von $D^{(n)}$
	18.2. Floyd-Warshall-Algorithmus
	18.2.1. Korrektheitsbeweis:
	18.2.2. Beweis der Invariante durch Induktion nach k
	18.3. Naive lösung \dots
	18.4. Johnson-Algorithmus
	18.4.1. Laufzeit des Johnson-Algorithmus
	10.4.1. Lauizeit des Johnson-Aigorithnus

Teil I. Sortieren

1.1. Bubblesort




Abbildung 1.1.: Bubblesort

1.1.1. Pseudocode

```
1 void bubblesort (int[] a) {
2    int n = a.length;
3    for (int i = 1; i < n; i++) {
4       for (int j = 0; j < n-i; j++) {
5         if (a[j] < a[j+1])
6         swap (a, j, j+1);
7     }
8    }
9 }</pre>
```

Schleifen-Invariante: Nach dem Ablauf der i-ten Phase gilt:

Die Feldpositionen n-i,...,n-i enthalten die korrekt sortierten Feldelemente

Beweis durch Induktion nach i $\stackrel{i=n-1}{\Longrightarrow}$ Sortierung am Ende korrekt.

1.1.2. Laufzeitanalyse

 $T(n)={\rm Zahl}$ der durchgeführten Elementvergleiche für eine Eingabemenge von
n Elementen

- 1. Phase n-1
- 2. Phase n-1
- 3. Phase n-1

:

i. Phase n-1

:

(n-1). Phase n-1

$$1+2+3+\ldots+(n+1)$$

$$T(n) = \sum_{i=1}^{n-1} i = \frac{n(n-1)}{2} \in O(n^2)$$

n	T_{real}
2^{10}	8ms
2^{11}	$11 \mathrm{ms}$
2^{12}	$26 \mathrm{ms}$
:	
2^{16}	5,819s
2^{17}	23,381s
:	
2^{20}	16min
÷	
2^{26}	52d

$$T_{real}(n) \approx cn^2 \ c \approx 10^{-6}$$

$$T_{real}(2n) \approx c \cdot (2n)^2 = 4cn^2 = 4T_{real}(n)$$

$$\frac{T_{real}(2n)}{T_{real}(n)} = 4$$

1.2. Heapsort

z.B. 21 6 4 7 12 5 3 11 14 17 19 8 9 10 42

Skizze




Abbildung 1.2. Heapsort (Ausgangssituation)

Indices innerhalb der Baumstruktur




Abbildung 1.3.: Indices

Heap-Eigenschaft




Abbildung 1.4.: Heap-Eigenschaft

1.2.1. Idee

Phase 1 Stelle die Heap-Eigenschaft überall her \Rightarrow größtes Element steht in der Wurzel

Phase 2 Tausche Wurzel mit letztem Feldelement (z.B. 42 mit 3)

- Entferne letztes Feldelement aus dem Baum
- Gehe erneut zu Phase $1\,$

Heapsort (Fortsetzung)

2.1. Pseudocode

```
heapify ( int[] a, int i, int n) {
1
2
     int j = 2i + 1;
3
                              //rechtes Kind von i existiert
4
       if (2i +2 < n)
5
        if ( a[j] < a[j+1])</pre>
       j = j + 1;
if (a[i] > a[j])
6
                              //j steht für Indes des größten Kindes
7
                              //Vater größer als Kind
                        //Vater größer als Kind
//Abbruch, weil heap bereits erfüllt
8
        break;
9
       swap(a,i,j);
                         //Tausch zwischen Vater und Kind
10
       i = j;
11
12 }
```

2.1.1. Phase: Bottom-up Strategie zum Heapaufbau

```
1 for ( int i = n/2; i \geq 0; i--)
2 heapify(a,i,n);
```

2.1.2. Phase: Sortierphase

```
1 for ( int i = n-1; i \geq 0; i--) {
2    swap(a,0,i);
3    heapify(a,0,i);
4 }
```


2.2. Korrektheitsbetrachtung

Invariante beim Heapaufbau: Beim Durchlauf der for-Schleife wird die Heapeigenschaft vom unteren Baumlevel bis zur Wurzel hergestellt.

Invariante für Sortierphase: Nach jedem weiteren Durchlauf der for-Schleife findet ein weiteres Element am Feldende seinen "richtigen Platz".

2.3. Laufzeitanalyse

T(n) = Zahl der Elementvergleiche.



n := Zahl der Elementek := Zahl der Schichten

2.3.1. Zusammenhang von n und k

$$n = \sum_{i=0}^{k-1} 2^i = 2^k - 1$$

Merke: Geometrische Reihe

$$\sum_{i=0}^{k-1} x^i = \frac{1 - x^k}{1 - x} \quad \text{mit } x \neq 1$$

2.3.2. Analyse Heapaufbau

$$\sum_{l=0}^{k-1} 2^l (k-1-l)$$

 2^l := Anzahl Knoten auf Level l

(k-1-l) := Leveldifferenz zwischen l
 und der Blattebene

$$\sum_{l=0}^{k-1} (k-1-l) \cdot 2^l = \sum_{l=0}^{k-1} (k-1) \cdot 2^l - \sum_{l=0}^{k-1} l \cdot 2^l = (k-1)(2^k-1) - 2\sum_{l=1}^{k-1} l 2^{l-1}$$

Nebenrechnung

$$\sum_{i=1}^{k-1} i \cdot x^{i-1} = \frac{d}{dx} \left(\sum_{i=0}^{k-1} x^i \right) = \frac{d}{dx} \left(\frac{x^k - 1}{x - 1} \right)$$
$$= \frac{kx^{k-1}(x - 1) - (x^k - 1)}{(x - 1)^2}$$

mit x = 2 folgt: $k \cdot 2^{k-1} - 2^k + 1$

$$= (k-1)(2^k - 1) - k2^k + 2^{k+1} - 2$$

$$= k2^k - 2^k - k + 1 - k2^k + 2^{k+1} - 2$$

$$= -2^k - k - 1 + 2^{k+1} \le 2^{k+1} \approx 2 \cdot n$$

 \Rightarrow Heapaufbau in lineare Zeit

2.3.3. Sortierphase


1. Versuch $n \cdot k$ mit $n = 2^k - 1 \Leftrightarrow k = \log_2(n+1) \approx n \cdot \log_2(n)$

2. Versuch (mit Verkleinerung der Liste)

$$\sum_{l=0}^{k-1} 2^l \cdot l = 2 \sum_{l=1}^{k-1} l \cdot 2^{l-1} = 2 \cdot (k \cdot 2^{k-1} - 2^k + 1) \ge k \cdot 2^{k-1} \approx n \cdot \log_2(n)$$

2.3.4. Fazit

Laufzeit $c \cdot n \cdot \log_2(n)$ wobei $c \in \mathbb{R}$



3.1. Landau-Notation

 $g, f: \mathbb{N} \to \mathbb{N}$

3.1.1. O(n)

 $g(n) \in O(f(n)) \Leftrightarrow c > 0 \land n_0 \in \mathbb{N}, \text{so dass für alle } n \geq n_0 \text{ gilt:} \\ g(n) \leq c \cdot f(n) \Leftrightarrow \lim_{n \to \infty} \sup \frac{g(n)}{f(n)} < \infty$

Beispiel

$$lim_{n\to\infty} \frac{n\log_2(n)}{n^2} = lim_{n\to\infty} \frac{\log_2(n)}{n} = lim_{n\to\infty} \frac{\frac{\ln(n)}{\ln(2)}}{n} \stackrel{\text{L' Hopital}}{=} lim_{n\to\infty} \frac{1}{\ln(2)} \cdot \frac{1}{n} = \frac{1}{\ln(2)} lim_{n\to\infty} \frac{1}{n} = 0$$

3.1.2. $\Omega(n)$

 $g(n) \in \Omega(f(n)) \Leftrightarrow c > 0 \land n_0 \in \mathbb{N}$, so dass für alle $n \ge n_0$ gilt: $g(n) \ge c \cdot f(n) \Leftrightarrow \lim_{n \to \infty} \inf \frac{g(n)}{f(n)} > 0$

Beispiel $g(n) = n^p$ $f(n) = n^q$ $p \ge q$

Behauptung $g(n) \in \Omega(f(n))$

 $\lim_{n\to\infty} \frac{n^p}{n^q} = \infty > 0$

3.1.3. $\Theta(n)$

$$g(n) \in \Theta(f(n)) \Leftrightarrow g(n) \in O(f(n)) \land g(n) \in \Omega(f(n))$$

Beispiel $q(n) = n^p + n^{p-1} + c \cdot n^2$ $f(n) = n^p$

Behauptung $g(n) \in \Theta(f(n))$

.... Rechnung

3.1.4. o(n)

$$g(n) \in o(f(n)) \Leftrightarrow \lim_{n \to \infty} \frac{g(n)}{f(n)} = 0$$

Beispiel $g(n) = n \cdot \log_2(n)$ $f(n) = n^2$ $\lim_{n \to \infty} \frac{g(n)}{f(n)} = 0$ siehe oben

Erklärung "g ist asymptotisch gesehen vernachlässigbar gegenüber f."

3.1.5. Notation Häufig wird: $O(n) = O(n^2) = O(n^2 \cdot \log_2(n))$ geschrieben, anstelle von: $O(n) \subseteq O(n^2) \subseteq O(n^2 \cdot \log_2(n))$ Missbrauch der Notation !!!

3.2. Mergesort (Divide and Conquer)

3.2.1. Pseudo-Code

```
1 int[] a; //Eingabefeld
2 int[] b; //Hilfsfeld
   void mergesort(int links, int rechts) {
4
5
       if (links > rechts) return;
6
       int mitte = (links+rechts)/2;
       mergesort(links, mitte);
7
       mergesort(mitte, rechts);
9
       merge(links, mitte, rechts);
10 }
11
12 void merge(int links, int mitte int rechts) {
       int i = links;
13
       int j = mitte+1;
14
15
       int k = links;
16
        while (i \leq mitte && j \leq rechts) {
           if (a[i] < a[j])</pre>
17
                b[k++] = a[i++];
18
19
            else
20
                b[k++] = a[j++];
21
        while (i \leq mitte)
22
           b[k++] = a[i++];
23
        while (j \le rechts)
24
25
           b[k++] = a[j++];
26
        for (k=links; k \le rechts; k++)
27
            a[k] = b[k];
28 }
```

3.2.2. Laufzeitanalyse

T(n)= Zahl der von Mergesort durchgeführten Elementarvergleiche \approx Laufzeit

$$T(n) = 2T(\frac{n}{2}) + n - 1 \approx 2T(\frac{n}{2}) + n \quad \text{mit} T(1) = 0$$

Korrekter wäre
$$T(n) = T(\lfloor \frac{n}{2} \rfloor) + T(\lceil \frac{n}{2} \rceil) + n - 1$$

Für ungerade Zahlen

$$\begin{split} T(n) &= 2 \cdot 2T \left(\frac{n}{2}\right) + n \stackrel{(1)}{=} 2 \left(2T \left(\frac{n}{4} + \frac{n}{2}\right) + n\right) = 4T \left(\frac{n}{4}\right) + 2n \\ &\stackrel{(2)}{=} 4 \cdot \left(2T \left(\frac{n}{8}\right) + \frac{n}{4}\right) + 2n = 8T \left(\frac{n}{8}\right) + 3n = \dots = 2^i \cdot T \left(\frac{n}{2^i}\right) + in \end{split}$$

$$T\left(\frac{n}{2}\right) = 2T\left(\frac{n}{4}\right) + \frac{n}{2} \tag{1}$$

$$T\left(\frac{n}{4}\right) = 2T\left(\frac{n}{8}\right) + \frac{n}{4} \qquad (2)$$

••••

$$T(1) = 0$$

Rekursionsende $\frac{n}{2^i} = 1 \Leftrightarrow 2^i = n \Leftrightarrow i = \log_2(n)$

$$T(n) = 2^{\log_2(n)} T\left(\frac{n}{2^{\log_2(n)}}\right) + n\log_2(n) = nT(1) + \log_2(n) = \log_2(n)$$

Abstraktion

T(n) = Laufzeit eines Divide & Conquer Algorithmus der ein Problem dadurch löst, das es in a Teilprobleme der Größe $\frac{n}{b}$ zerlegt wird, die rekursiv gelöst werden und anschließend kombiniert werden.

$$T(n) = a \cdot T\left(\frac{n}{b}\right) + n^{\alpha}$$
 $\alpha > 0$ mit $T(1) = 0$

$$T(n) = aT\left(\frac{n}{b}\right) + n^{\alpha} \stackrel{(1)}{=} a^{2}T\left(\frac{n}{b^{2}}\right) + a\left(\frac{n}{b}\right)^{\alpha} + n^{\alpha}$$

$$(1) \qquad T\left(\frac{n}{b}\right)=aT\left(\frac{n}{b^{2}}\right)+\left(\frac{n}{b}\right)^{\alpha}\stackrel{(2)}{=}a^{3}T\left(\frac{n}{b^{3}}\right)+a^{2}\left(\frac{n}{b^{2}}\right)^{\alpha}+a^{1}\left(\frac{n}{b^{1}}\right)^{\alpha}+a^{0}\left(\frac{n}{b^{0}}\right)^{\alpha}$$

$$(2) T\left(\frac{n}{b^2}\right) = aT\left(\frac{n}{b^3}\right) + \left(\frac{n}{b^2}\right)^{\alpha} = a^iT\left(\frac{n}{b^i}\right) + \sum_{j=0}^{i-1} a^j \left(\frac{n}{b^j}\right)^{\alpha} = a^iT\left(\frac{n}{b^i}\right) + n^{\alpha} \sum_{j=0}^{i-1} \left(\frac{a}{b^{\alpha}}\right)^j$$

$$mit i = \log_b(n) \land x = \frac{a}{b^{\alpha}}$$

•••

$$T(1) = 0$$

4.1. Master-Theorem

$$T(n) = T\left(\frac{n}{b} \cdot a + n^{\alpha}\right)$$

$$T(1) = 0$$

$$T(n) = a^{i}T\left(\frac{n}{b^{i}}\right) + n^{\alpha} \sum_{j=0}^{i-1} \left(\frac{a}{b^{\alpha}}\right)^{j}$$

$$\frac{\text{o.B.d.A}}{n = b^k \Leftrightarrow k = \log_b(n)}$$

4.1.1. Fall 1

$$(\frac{a}{b^{\alpha}}) < 1 \Leftrightarrow a < b^{\alpha} \Leftrightarrow \log_b(a) < \alpha$$

$$\sum_{j=0}^{k-1} x^j = \frac{x^k - 1}{x - 1} \quad \text{für } x \neq 1$$

$$\Rightarrow \sum_{j=0}^{k-1} \left(\frac{a}{b^{\alpha}}\right)^j \le \frac{1}{1 - \frac{a}{b^{\alpha}}} = c'$$

$$T(n) = a^k T(1) + n^{\alpha} \cdot c'$$
$$= c \cdot n^{\log_b(a)} + c' \cdot n^{\alpha} = \Theta(n^{\alpha})$$

$$\textbf{Nebenbedingung} \quad a^{\log_b(n)} = \left(b^{\log_b(a)}\right)^{\log_b(n)} = \left(b^{\log_b(n)}\right)^{\log_b(a)} = n^{\log_b(a)}$$

4.1.2. Fall 2

$$\left(\frac{a}{b^{\alpha}}\right) > 1 \Leftrightarrow \log_b(a) > \alpha$$

$$\sum_{j=0}^{k-1} \left(\frac{a}{b^{\alpha}}\right)^j = \left(\frac{\left(\frac{a}{b^{\alpha}}\right)^{\log_b(n)} - 1}{\left(\frac{a}{b^{\alpha}}\right) - 1}\right) \leq \left(\frac{a}{b^{\alpha}}\right)^{\log_b(n)} \cdot c'' = \frac{a^{\log_b(n)}}{b^{\alpha \log_b(n)}} = \frac{n^{\log_b(\alpha)}}{n^{\alpha}}$$

$$T(n) = c \cdot n^{\log_b(a)} + n^{\alpha} \cdot \frac{n^{\log_b(a)}}{n^{\alpha}} \cdot c'' = \Theta\left(n^{\log_b(a)}\right)$$

4.1.3. Fall 3

$$\left(\frac{a}{b^{\alpha}}\right) = 1 \Leftrightarrow a = b^{\alpha} \Leftrightarrow \log_b(a) = \alpha$$

$$T(n) = c \cdot n^{\log_b(a)} + n^{\alpha} \cdot \log_b(n) = \Theta(n^{\alpha} \cdot \log(n))$$

4.1.4. Beispiel: Mergesort

$$T(n) = 2T\left(\frac{n}{2}\right) + n$$

$$T(1) = 0$$

Ermittle
$$a = 2$$
 $b = 2$ $\alpha = 1$

$$\log_2(2) = 1 = \alpha \Rightarrow 3$$
. Fall $\Rightarrow \Theta(n \cdot \log(n))$

4.2. Schnelle Multiplikation langer Zahlen

$$A = \boxed{a_{n-1} \quad \dots \quad a_i \quad \dots \quad a_2 \quad a_1 \quad a_0} \quad a_i \in B = \{0, 1\}$$
$$= \sum_{i=1}^{n-1} a_i 2^i$$

$$\mathbf{B} = \boxed{\begin{array}{c|cccc} b_{n-1} & \dots & b_2 & b_1 & b_0 \\ \\ = \sum_{i=0}^{n-1} b_i 2^i & & & \end{array}}$$

Frage Wie schnell können wir zwei n-stellige Binärzahlen addieren/subtrahieren/multiplizieren?

Addition $\Theta(n)$

4.2.1. Schulmethode zur Multiplikation

 n^2 Aufwand zur Ermittlung der Partialprodukte + $n\cdot$ Kosten für die Addition von Zahlen der Länge 2n $\ \Rightarrow \Theta(n^2)$

Ziel $o(n^2)$ $O(n^{1,58})$

4.2.2. Karazuba Ofman

$$A = \boxed{a_{n-1} \mid \dots \mid a_{\frac{n}{2}}} \qquad \boxed{a_{\frac{n}{2}-1} \mid \dots \mid a_0}$$
$$= A_1 \qquad = A_0$$

$$A = A_0 + A_1 2^{\frac{n}{2}}$$

$$A \cdot B = (A_0 + A_1 2^{\frac{n}{2}})(B_0 + B_1 2^{\frac{n}{2}})$$
$$= A_0 B_0 + A_0 B_1 2^{\frac{n}{2}} + A_1 B_0 2^{\frac{n}{2}} + A_1 B_1 2^n$$

Legende markierte Elemente haben die Länge $\frac{n}{2}$

Anmerkung Addition von Zahlen der Länge 2n

Sei T(n) die Laufzeit dieser rekursiven Methode zur Multiplikation zweier n-stelliger Zahlen:

$$T(n) = 4 \cdot T\left(\frac{n}{2}\right) + c \cdot n$$
 $T(1) = c$

Mastertheoreme

$$\begin{aligned} a &= 4 \quad b = 2 \quad \alpha = 1 \quad \log_2(4) = 2 > \alpha \\ \Rightarrow T(n) &= \Theta(n^2) \\ \Rightarrow \text{kein Gewinn bisher!!!} \end{aligned}$$

Ziel Ermittle Partialprdoukte auf anderem Weg

1.)
$$(A_0 + A_1) \cdot (B_0 + B_1) = A_0B_0 + A_0B_1 + A_1B_0 + A_1B_1 = P$$

- 2.) $A_0 \cdot B_0$
- (3.) $A_1 \cup B_1$

$$\Rightarrow (A_0B_1 + A_1B_0) = (P - (A_0B_0) - (A_1B_1))$$

Es verbleiben 3 Multiplikationen und Additionen

$$AB = A_0B_0 + (P - (A_0B_0) - (A_1B_1)) + A_1B_12^n$$

Mastertheoreme

$$T(n) = 3 \cdot T\left(\frac{n}{2}\right) + n$$

$$a=3, \quad b=2, \quad \alpha=1$$

$$\log_2(3) > 1 \implies 2$$
. Fall

$$\Rightarrow \Theta\left(n^{\log_2(3)}\right) = \Theta\left(n^{1,5849625}\right)$$

4.2.3. Akra-Brazzi Theorem

Beispiel $T(n) = 2T\left(\frac{n}{2}\right) + \log_2(n)$

$$T(n) = \begin{cases} aT\left(\frac{n}{b}\right) + g(n) & n > n_0\\ h(n) & 1 \le n \le n_0 \end{cases}$$

$$T(n) = \Theta\left(n^{\alpha}\left(1 + \int_{1}^{n} \frac{g(x)}{x^{\alpha+1}} dx\right)\right)$$
 mit α , so dass gilt: $\frac{a}{b^{\alpha}} = 1$

5.1. Akra-Brazzi

$$\begin{split} T(n) &= a \cdot T\left(\frac{n}{b}\right) + g(n) \\ T(1) &= c \\ T\left(n\right) &= \Theta\left(n^{\alpha}\left(1 + \int_{1}^{n} \frac{g\left(x\right)}{x^{1+\infty}} dx\right)\right) \quad \text{mit } \frac{a}{b^{\alpha}} = 1 \quad \alpha = \log_{b}(a) \\ \text{z.B. } T(n) &= 2 + \frac{n}{2} + \log(n) \end{split}$$

Beweisidee

$$\begin{split} &T(\frac{n}{b}) = aT(\frac{n}{b^2}) + g(\frac{n}{b}) \\ &T(n) = a\left(aT\left(\frac{n}{b^2}\right) + g\left(\frac{n}{b}\right)\right) + g\left(n\right) = a^2 + \frac{n}{b^2} + a^1g\left(\frac{n}{b^1}\right) + a^0g\left(\frac{n}{b^0}\right) \\ &\Rightarrow a^iT\left(\frac{n}{b^i}\right) + \sum_{j=0}^{i-1}a^ig\left(\frac{n}{b^2}\right) \quad \text{Rekursionsende für } \mathbf{r} = \log_b(b) \\ &\Theta(a^{\log_b(n)}) = \Theta(n^\alpha) \\ &\sum_{i=0}^{\log(n)-1}a^ig\left(\frac{n}{b^\alpha}\right) \approx \int_0^{\log_b(n)}a^jg\left(\frac{n}{b^j}\right)dj \end{split}$$

$$x = \frac{n}{b^{j}} = n \cdot b^{-j} = n \cdot e^{-j \ln(b)}$$

$$\Rightarrow d_{j} = \frac{1}{-\ln(b)x} dx$$

$$a^{j} = b^{\log_{b}(a)j} = b^{\alpha j} = (b^{j})^{\alpha} = \left(\frac{n}{x}\right)^{\alpha}$$

$$= \int_{n}^{1} \left(\frac{n}{x}\right)^{\alpha} g(x) \left(\frac{1}{-\ln(b)x}\right) dx = \frac{n^{\alpha}}{\ln(b)} \cdot \int_{1}^{n} \frac{g(x)}{x^{1+\infty}} dx$$

q.e.d

5.2. Lineare Rekursionsgleichungen

5.2.1. Fibonacci-Zahlen

$$f_n = f_{n-1} + f_{n-2}$$

$$f_0 = 0$$

$$f_1 = 1$$

n	0	1	2	3	4	5	6	7	
f(n)	0	1	1	2	3	5	8	13	

Abbildung 5.1.: Fibonacci-Zahlen

5.2.2. Methode der erzeugenden Funktionen

$$F(Z) = \sum_{n=0}^{\infty} f_n Z^n = f_0 \cdot Z^0 + f_1 \cdot Z^1 + \sum_{n=2}^{\infty} (f_{n-1} + f_{n-2}) \cdot Z^n$$

$$= Z + \sum_{n=2}^{\infty} f_{n-1} Z^n + \sum_{n=2}^{\infty} f_{n-2} Z^n$$

$$= Z + Z \sum_{n=2}^{\infty} f_{n-1} Z^{n-1} + Z^2 \sum_{n=2}^{\infty} f_{n-2} Z^{n-2}$$

$$\Leftrightarrow F(Z) = Z + Z \cdot F(Z) + Z^2 \cdot F(Z)$$

$$\Leftrightarrow -Z = Z^2 F(Z) + Z F(Z) - F(Z) = F(Z)(Z^2 + Z - 1)$$

$$F(Z) = -\frac{Z}{Z^2 + Z + 1}$$

5.2.3. Einschub: Beispiel Reihenentwicklung

$$\frac{1}{1-Z} = \sum_{n=0}^{\infty} Z^n$$

$$\Rightarrow F(Z) = -\frac{Z}{Z^2 + Z + 1}$$

5.2.4. Nullstellen des Nennerpolynoms

$$Z^2 + Z = 1 \quad | + (\frac{1}{2})^2$$
 Goldener Schnitt
$$\Leftrightarrow (Z + \frac{1}{2})^2 = \frac{5}{4}$$

$$\Leftrightarrow Z_{1/2} = -\frac{1}{2} \pm \frac{\sqrt{5}}{2}$$

$$\Rightarrow Z^2 + Z + 1 = (Z + \phi)(Z + \overline{\phi})$$

5.2.5. Partialbruchzerlegung

$$\frac{A}{Z+\phi} + \frac{B}{Z+\overline{\phi}} = \frac{A \cdot (Z+\overline{\phi}) + B(Z+\phi)}{(Z+\phi)(Z+\overline{\phi})}$$

$$\Rightarrow AZ + BZ = -Z \Leftrightarrow A+B = 1 \quad (1)$$

$$A\overline{\phi} + B\phi = 0 \Leftrightarrow B = -\frac{A\overline{\phi}}{\phi} \quad (2)$$

$$(2) \text{ in } (1) \quad A - \frac{A\overline{\phi}}{\phi} = -1 \Leftrightarrow A\left(1 - \frac{\overline{\phi}}{\phi}\right) = -1$$

$$\Leftrightarrow A = -\frac{1}{\sqrt{5}}\phi$$

$$\Rightarrow B = \frac{1}{\sqrt{5}}\overline{\phi}$$

5.2.6. Lösung

$$F(Z) = \frac{-Z}{Z^2 + Z + 1} = -\frac{1}{\sqrt{5}} \frac{\phi}{Z + \phi} + \frac{1}{\sqrt{5}} \frac{\overline{\phi}}{Z + \overline{\phi}}$$

$$= \frac{1}{\sqrt{5}} \left(\frac{1}{1 + \frac{Z}{\phi}} - \frac{1}{1 + \frac{Z}{\overline{\phi}}} \right) = \frac{1}{\sqrt{5}} \left(\frac{1}{1 - \phi Z} - \frac{1}{1 - \overline{\phi} Z} \right)$$

$$= \frac{1}{\sqrt{5}} \left(\sum_{n=0}^{\infty} (\phi Z)^n - \sum_{n=0}^{\infty} (\overline{\phi} Z)^n \right) = \sum_{n=0}^{\infty} \frac{1}{\sqrt{5}} \left(\phi^n - \overline{\phi}^n \right) \cdot Z^n$$

$$f_n = \frac{1}{\sqrt{5}} \left(\phi^n - \overline{\phi}^n \right) \quad \text{mit } \phi = 1,681... \quad \overline{\phi} = -0,681...$$

5.3. Quicksort (Divide and Conquer)

- \Rightarrow Tausche 15 mit 10
- Bewege Zeiger erneut
- \Rightarrow Tausche 5 und 24
- Bewege Zeiger erneut
- \Rightarrow Tausche 16 und 2
- Bewege Zeiger erneut
- \Rightarrow i wird größer als j \Rightarrow Abbruch (tausche Pivotelement mit letztem Element in Teilliste 1)
- ⇒ es ergeben sich zwei Teillisten


best-case
$$T(n) = 2T\left(\frac{n}{2}\right) + n = \Theta(n \log n)$$

worst-case
$$T(n) = T(n-1) + n = \Theta(n^2)$$

6.1. Quicksort

6.1.1. Pseudo-Code

```
void quicksort(int[] a, int links, int rechts) {
       if (links > rechts) return;
        int mitte = partition(a, links, rechts);
3
        quicksort(a, links, mitte-1);
4
        quicksort(a, mitte+1, rechts);
5
6
8
   int partition(int[] a, int links, int rechts) {
9
        int r = random(links, rechts);
10
        swap(a, r, rechts);
11
        int pivot = a[rechts];
12
       int i = links;
13
       int j = rechts-1;
14
        while (i \le j) {
15
            if (a[i] > pivot) {
16
                swap(a, i, j);
17
            } else {
18
19
                i++;
20
            }
21
        }
22
        swap(a, i, rechts);
23
        return i;
24 }
```



Schleifen-Invariante:

a[k] > p für j < k < rechts $a[k] \le p$ für links < k < i

24

Abbildung 6.1.

6.1.2. Zufallspermutation

```
void randomPermutation(int[] a) {
   int n = a.length;
   for (int i = n-1); i > 0; i--) {
      int r = random(0,i); // gleichverteilte Zufallszahl im Intervall [0,i)
      swap(a,r,i);
   }
}
```

6.1.3. Einschub: Stochastik

Fairer Würfel (Erwartungswert):

X sei Zufallsvariable $\hat{=}$ Anzahl Augen

$$Pr(X = x_i) \quad x_i \in \{1, 2, 3, 4, 5, 6\}$$

$$E(X) = \sum_{i=1}^{6} x_i \cdot Pr(X = x_i) = \frac{1}{6} \cdot \sum_{i=1}^{6} x_i = \frac{1}{6} \cdot \frac{7 \cdot 6}{2} = 3, 5$$

Fairer Würfel (Erste Sechs):

X sei Zufallsvariable $\hat{=}$ Zahl der benötigten Würfe bis zum Auftreten der ersten 6.

$$x_i \in N$$

$$E(X) = \sum_{i=1}^{\infty} i \cdot Pr(X=i) = \frac{1}{6} \cdot \sum_{i=1}^{\infty} i \cdot \left(\frac{5}{6}\right)^{i-1}$$

Mit der Ableitung der geometrischen Reihe, $\frac{1}{(1-x)^2}$ folgt:

$$=\frac{1}{6}\cdot\left(\frac{1}{\left(1-\frac{5}{6}\right)^2}\right)=6$$

6.1.4. Laufzeitanalyse

T(n) = Erwartungswert der Laufzeit von Quicksort bei zufällig gleichverteilter Eingabe-Partition.




Abbildung 6.2.

Lösen durch Einsetzten

$$T(n) = n + \frac{2}{n} \sum_{i=1}^{n} T(i-1) = n + \frac{2}{n} \sum_{i=0}^{n-1} T(i)$$

$$\Leftrightarrow n \cdot T(n) = n^2 + 2 \sum_{i=0}^{n-1} T(i)$$

$$\Leftrightarrow 2(n-1) \cdot T(n-1) = (n-1)^2 + 2 \sum_{i=0}^{n-2} T(i)$$

$$\Leftrightarrow (1) - (2)nT(1) - (n-1)T(n-1) = n2 - (n-1)^2 + 2T(n-1)$$

$$\Leftrightarrow nT(n) = (n+1)T(n-1) + 2n - 1$$

$$\Leftrightarrow T(n) \le \frac{n+1}{n} T(n-1) + 2 \le \frac{n+1}{2} \left(\frac{n}{n+1} \cdot T(n-2) + 2 \right) + 2$$


$$= \frac{n+1}{n-1} T(n-2) + \frac{n+1}{n} \cdot 2 + 2$$

$$\le \frac{n+1}{n-1} \left(\frac{n-1}{n-2} T(n-3) + 2 \right) + \frac{n+1}{n} \cdot 2 + 2 \cdot 1$$

$$= \frac{n+1}{n-2} T(n-3) + 2 \cdot \frac{n+1}{n-1} + 2 \cdot \frac{n+1}{n} + 2 \cdot \frac{n+1}{n+1}$$

$$\Rightarrow T(n) \le \frac{n+1}{n-(k-1)} T(n-k) + 2(n+1) \sum_{i=1}^{k-2} \frac{1}{n-i} \quad \text{endet für k = n-1}$$

$$T(n) = 2(n+1) \sum_{i=-1}^{n-3} \frac{1}{n-i} = 2(n+1) \sum_{j=3}^{n+1} \frac{1}{j} \le 2(n+1) H_{n+1} \in O(n \log n) \quad \text{mit j=n-i}$$



6.2. Median in Linearzeit

Median $\; \stackrel{.}{=} \; \frac{n}{2}$ -kleinste Element in einer Folge von
n Elementen

Verallgemeinerung

Finde das k-t kleinste Elemente in der Folge

Naive Strategie: $O(k \cdot n)$

Idee

1 select(int[] a, int k) {}

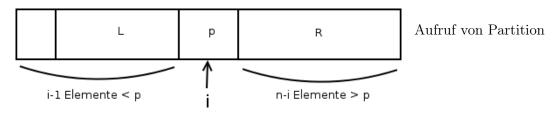


Abbildung 6.3.

- **1. Fall** $k = i \Rightarrow \text{Pivot Element war gesucht}$
- 2. Fall $k < i \Rightarrow$ suche rekursiv das k-t kleinste Element in L
- 3. Fall $k > i \Rightarrow$ suche rekursiv das (k-i)-t kleinste Element in R

7.1. Quicksort

$$T(n) = \frac{1}{n} \sum_{i=1}^{n} T(i-1) + T(n-i) + n \quad \in O(n \log(n))$$

7.2. Quickselect

$$T(n) = n + \frac{1}{n} \sum_{i=1}^{n} max(T(i-1), T(n-i))$$

Behauptung Select $\in O(n)$, also $T(n) = c \cdot n$

Beweis Induktion

$$T(n) = n + \frac{1}{n} \sum_{i=1}^{n} \max(c(i-1), c(n-i))$$

$$= n + \frac{1}{n} \cdot c \sum_{i=1}^{n} \max((i-1), (n-i))$$

$$= n + \frac{1}{n} \cdot c \cdot 2 \left(\sum_{i=1}^{n-1} i - \sum_{i=1}^{\frac{n}{c}-1} i \right)$$

$$= n + \frac{1}{n} \cdot c \cdot Z \left(\frac{(n-1)n}{Z} - \frac{(\frac{n}{2}-1)\frac{1}{2}}{Z} \right)$$

$$= n + \frac{1}{n} c \left(n(n-1) - \frac{n}{2} \left(\frac{n}{2} - 1 \right) \right) = n + \frac{1}{n} \cdot c \left(n^2 - n - \frac{n^2}{4} + \frac{n}{2} \right)$$

$$= n + \frac{1}{n} c \left(\frac{3}{4} n^2 - \frac{1}{2} n \right) = n + c \left(\frac{3}{4} n - \frac{1}{2} \right)$$

$$\Rightarrow cn = n + c \left(\frac{3}{4} n - \frac{1}{2} \right) = n + \frac{3}{4} cn - \frac{1}{2} c$$

$$\Rightarrow cn \ge n + \frac{3}{4} cn \Leftrightarrow c \ge 4$$

$$q.e.d$$

8.1. Verallgemeinerung von Akra-Brazzi

$$T_n = \left[\sum_{i=1}^k a_i T(\frac{n}{b_i})\right] + g(n)$$

Beispiel

$$T_n = 1 \cdot T\left(\frac{n}{3}\right) + 1 \cdot T\left(\frac{2n}{3}\right) + n$$
$$T_n = \theta\left(n^{\alpha}\left(1 + \int_1^n \frac{g(x)}{x^{1+\alpha}} dx\right)\right)$$

Klassisch $\alpha = \log_b(a), \frac{a}{b^{\alpha}} = 1$

Jetzt Bestimmte α so, dass gilt:

$$\sum_{i=1}^{k} \frac{a_i}{b_i^{\alpha}} = 1$$

$$a_1 = a_2 = 1, \quad b_1 = 3, \quad b_2 = \frac{3}{2}, \quad g(n) = n$$

$$\frac{1}{3}^{\alpha} + \frac{2}{3}^{\alpha} \stackrel{!}{=} 1 \Rightarrow \alpha = 1$$

$$T(n) = \Theta\left(n\left(1 + \int_1^n \frac{x}{x^{1+1}} dx\right)\right) = \Theta(n\ln(n))$$

8.2. Median der Mediane

Gruppierung in 5er Päckchen




Abbildung 8.1.

Mediane

Wortlaut Teile die n Elemente in 5-er Gruppen. Bestimme innerhalb jeder Gruppe den Median. Bestimme nun den Median der Mediane. Wähle diesen Median als Pivot Element.

$$\exists \frac{3n}{10}$$
 Elemente $\leq p \geq \exists \frac{3n}{10}$ Elemente (±1 wegen p)

8.2.1. Deterministische Variante für k-Select

Wähle zu Beginn den Median der Mediane als Pivot Elemente. Unterteile nun die Folge anhand von p in zwei Teilfolgen und verfahre von nun an analog zur randomisierten Variante von k-Select.

8.2.2. Laufzeitanalyse für den worst-case

$$T(n) = T\left(\frac{n}{5}\right) + n + T\left(\frac{7n}{10}\right)$$

$$A_1 = \frac{n}{5}, \quad A_2 = n, \quad A_3 = \frac{7n}{10}$$

 $A_1 =$ Laufzeit zur rekursiven Bestimmung des Medians der Mediane

 $A_2 =$ Laufzeit zur Aufteilung in Teilfolgen

 $A_3 =$ Laufzeit für den Aufruf von k-Select für größere Teilfolgen, die aber sicher $\leq n - \frac{3n}{10} - \frac{7n}{10}$ hat.

Wende die verallgemeinerte Form von Akra-Brazzi an:

$$g(n) = n$$
, $a_1 = a_2 = 1$, $b_1 = 5$, $b_2 = \frac{10}{7}$

Bestimme

$$\alpha = \left(\frac{1}{5}\right)^{\alpha} + \left(\frac{7}{10}\right)^{\alpha} = 1$$

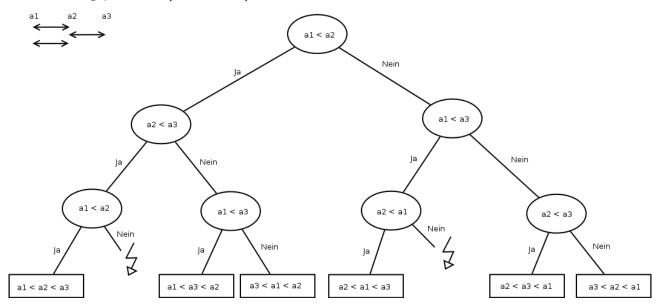
$$\Leftrightarrow \left(\frac{2}{10}\right)^{\alpha} + \left(\frac{7}{10}\right)^{\alpha} = 1$$

$$\Rightarrow 0 < \alpha < 1$$

$$n^{\alpha}\left(1+\int_{1}^{n}\frac{x}{x^{1+\alpha}}dx\right)=n^{\alpha}\left(1+\int_{1}^{n}x^{-\alpha}dx\right)=n^{\alpha}\left(1+\left[\frac{1}{1-\alpha}x^{-\alpha+1}\right]_{1}^{n}\right)=n^{\alpha}\left(1+\frac{1}{1-\alpha}\left(n^{-\alpha+1}-1\right)\right)$$

8.3. Untere Schranke für vergleichsbasierte Sortierverfahren

Entscheidungsproblem: (Bubbelsort)



Ein Entscheidungsbaum für einen vergleichsbasierten Sortieralgorithmus besteht aus inneren Knoten, die mit der Vergleichsoperation $a_i < a_j$ beschriftet sind, wobei sich die Indizes i, j auf die Position der Elemente in der Eingabefolge beziehen.

Die Blätter des Entscheidungsbaums sind mit den Permutationen beschriftet, die sich nach korrekter Sortierung ergeben.

Jeder korrekte Sortieralgorithmus muss zu einem Entscheidungsbaum mit mindestens n! Blättern korrespondieren.


9.1. Vergleichsbasierte Sortieralgorithmen

9.1.1. Worst-case Laufzeit

eines vergleichsbasierten Sortieralgorithmus

- $\stackrel{\circ}{=}\,$ maximale Tiefe des zugehörigen Entscheidungsbaums
- $\hat{=}$ mittlere Tiefe der Blätter im zugehörigen Entscheidungsbaums

Sei T_{max} die maximale Baumtiefe in einem binären Baum. Betrachte nun zunächst den vollständigen binären Baum mit #Blätter ≤ 2 .



Unter Schranke $t_{max} \ge \log_2(n!) = \Omega(n \log n) = \log_2(n!) \le t_{mean}$

Abbildung 9.1.

Herleitung


$$\ln(n!) = \ln(n(n-1) \cdot (n-2) \cdot \dots \cdot 2 \cdot 1) = \ln(n) + \ln(n-1) + \dots + 1$$
$$= \sum_{i=1}^{n} \ln(i) \ge \int_{1}^{n} \ln(x) dx = [x \ln(x) - x]_{1}^{n} = n \ln(n) - n + 1$$

$$\Rightarrow n! \ge e^{n \ln(n) - n + 1} = e \cdot e^{-n} \cdot \left(e^{\ln(n)}\right)^n = e \cdot e^{-n} \cdot n = e\left(\frac{n}{e}\right)^n$$

Stirling $n! \approx \sqrt{2\pi n} (\frac{n}{e})^n$

9.1.2. Lemma: Mittlere Tiefe der Blätter in einem Entscheidungsbaum $> \log_2(n)n$

Beweis Induktion nach m (Blattanzahl)



Untere Schranke $m_1, m_2 =$ Blattanzahl im linken bzw. rechten Teilbaum der Wurzel

Abbildung 9.2.

Induktions Anfang: m = 1 $t_{mean} = \log_2(1) = 0$

Induktions Behauptung: $t_{mean} \ge \log_2(m)$

Induktions Schritt: Sei $m_1 < m, m_2 < m$ (1) und $m_1 + m_2 = m$ (2)

b $\hat{=}$ Blatt im Entscheidungsbaum T_b

 $1 \triangleq \text{Blatt im linken Teilbaum } T_l$

r $\hat{=}$ Blatt im rechten Teilbaum T_r

$$t_{mean}^{links} \ge \log_2(m_1)$$
 und $t_{mean}^{rechts} \ge \log_2(m_2)$

$$\frac{1}{m} \sum_{l} \cdot t_l = t_{mean}^{links} \ge \log_2(m_1)$$

Verfahre analog für rechts.

$$\sum_{b} T_{b} = \sum_{l} (T_{l} + 1) + \sum_{r} (T_{r} + 1) \ge m_{1} + m_{2} + m_{1} \log_{2}(m_{1}) + m_{2} \log_{2}(m_{2})$$

Unter der Annahme, dass das Minimum bei $\frac{m}{2}$ liegt:

$$m_1 \log_2(m_1) + m_2 \log_2(m_2) \ge \frac{m}{2} \log_2\left(\frac{m}{2}\right) \cdot 2 = m \log_2\left(\frac{m}{2}\right) \quad \text{mit (2)}$$

Es folgt somit:

$$t_{mean} = \frac{1}{m} \sum_{b} T_b \ge \frac{1}{m} \left(m + m \log_2 \left(\frac{m}{2} \right) \right) = 1 + \log_2 \left(\frac{m}{2} \right) = 1 + \log_2(m) - 1 = \log_2(m)$$

q.e.d

9.2. Radix-Sort

9.2.1. Beispiel:

```
10 1
       0 1 0
              1 00
                      001
              1 01
01 \ 0
       100
                      010
00 1
       1 1 0
              0 01
                      011
11 1
       1 \ 0 \ 1
               0 10
                      100
100
       0 \ 0 \ 1
              1 10
                      101
01 1
       1 1 1
              1 11
                      110
11 0
       0 \ 1 \ 1
              0 11
                      111
```

Wichtig Beginne die Sortierung mit dem niedrigsten Bit

9.2.2. Pseudo-Code

```
void radixsort(int[] a) { // positives Element
2
        int n = a.length;
3
        int[] b0 = new int[n];
        int[] b1 = new int[n];
4
        int n0, n1;
5
 6
 7
        for (int i=0; i<32; i++) {</pre>
8
             n0 = n1 = 0;
9
             for (int j=0; j<n; j++) {</pre>
                  if (a[j] & (1<<i)) { // i-tes Bit von a[j]</pre>
10
11
                       b1[n1] = a[j];
12
                       n1 = n1+1;
13
                  } else {
14
                       b0[n0] = a[j];
15
                       n0 = n0+1;
16
                  }
17
             }
18
         for (int j=0; j<n0; j++)</pre>
19
20
             a[j] = b0[j];
         for (int j=0; j<n1; j++)
   a[n0+j] = b1[j];</pre>
21
22
23
   }
```

9.3. Binäre Suchbäume

Zahlen 12, 8, 3, 16, 24, 17, 10, 21, 14, 9




Abbildung 9.3.: Knotenorientierte Speicherung

10.1. Binärer Suchbaum




Abbildung 10.1.: Binärer Suchbaum

10.2. Pseudo-Code

```
class Node {
                                  // info ist optional
3
       int key, info;
       Node left, right, parent; // parent ist optional
4
5
6
7
   int height(Node node) {
       if (node = NULL) return 0;
8
9
       return height;
10
11
12
   Node insert(Node node, int x) {
13
       if (node == NULL)
14
            return new Node(x, NULL, NULL);
15
16
       if (node.key > x)
17
            node.left = insert(node.left, x);
18
            node.right = insert(node.right, x);
19
20
       return node;
21
22
   void inorder(Node node) {
23
24
       if (node == NULL) return;
25
        inorder(node.left) // linke Hälfte
26
        print(node)
27
        inorder(node.right) // rechte Hälfte
28 }
```

10.3. AVL-Bäume

Ziel Binärer Suchbaum mit garantierter Such-, Einfüge- und Löschzeit $O(\log n)$

Idee Definiere eine Balancebedingung, die dafür sorgt, dass die Baumstruktur möglichst nahe an der Idealstruktur eines vollständigen binären Baumes liegt.

Aber gleichzeitig soll es möglich sein "schnell" Strukturänderungen beim Einfügen und Löschen vorzunehmen.

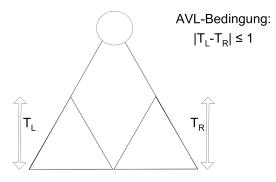



Abbildung 10.2.: AVL-Baum

10.4. Laufzeitanalyse

Ziel Analyse der erwarteten maximalen Tiefe randomisierter binärer Suchbäume

Sei der Schlüssel der Wurzel das i-kleinste Element



Elementen

in i Element

Abbildung 10.3.

 $T_n \stackrel{.}{=}$ maximale Tiefe eines randomisierten Suchbaums mit $\{1,...,n\}$

37

Für den Fall, dass i als Wurzelknoten gewählt wird gilt:

$$T_n = \max\{T_{i-1}, T_{n-i}\} + 1$$

$$X_n = 2^{T_n} \text{ exponentielle Tiefe}$$

$$2^{T_n} = 2^{1+\max\{T_{i-1}, T_{n-1}\}} = 2 \cdot 2^{\max\{T_{i-1}, T_{n-1}\}} = 2 \cdot \max\{2^{T_{i-1}}, 2^{T_{n-1}}\}$$

$$\Rightarrow X_n = 2 \cdot \max\{X_{i-1}, X_{n-1}\}$$

Mit der Abschätzung: $max\{2^{T_1},2^{T_2}\} \leq 2^{T_1}+2^{T_2}$ folgt:

$$E(X_n) = E\left(\sum_{i=1}^n \frac{1}{n} \cdot 2 \cdot \max\{X_{i-1}, X_{n-1}\}\right)$$

$$= \frac{2}{n} \sum_{i=1}^n E\left(\max\{X_{i-1}, X_{n-1}\}\right) \le \frac{2}{n} \sum_{i=1}^n E\left(X_{i-1} + X_{n-1}\right) = \frac{2}{n} \sum_{i=1}^n \left[E(X_{i-1}) + E(X_{n-i})\right] \le \frac{4}{n} \sum_{i=0}^{n-1} E(X_i)$$

$$n \cdot E(X_n) = 4 \cdot \sum_{i=0}^{n-1} E(X_i) \quad (1)$$

$$(n-1) \cdot E(X_{n-1}) = 4 \cdot \sum_{i=0}^{n-2} E(X_i) \quad (2)$$

$$nE(X_n) - (n-1)E(X_{n-1}) = 4E(X_n) \quad (1) - (2)$$

$$\Leftrightarrow nE(X_n) = (n+3)E(X_{n-1})$$

$$E(X_n) = \frac{n+3}{n} E(X_{n-1}) = \frac{n+3}{n} \cdot \frac{n+2}{n-1} E(X_{n-2}) = \prod_{i=0}^{n-1} \frac{n+3-i}{n-i} = \frac{n+3}{n} \cdot \frac{n+2}{n-1} \cdot \frac{n+1}{n-2} \cdot \frac{n}{n-3} \cdot \dots \cdot \frac{6}{3} \cdot \frac{8}{2} \cdot \frac{4}{1}$$

Mit der "Jensenschen Ungleichung" folgt:

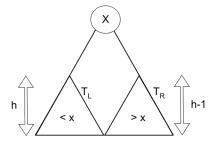
$$\sum_{i} Pr(T = t_i) \cdot f(t_i) \ge f\left(\sum_{i} Pr(T = t_i) \cdot t_i\right) = \frac{(n+3)(n+2)(n+1)}{3!} \cdot c \Rightarrow E(X_n) \in O(n^3)$$

$$X_n = 2^{T_n}, E(X_n) = E(2^{T_n})$$

$$E(f(T)) \ge f(E(T)) \Leftrightarrow fkonvex$$

$$c \cdot n^3 > 2^{E(T_n)}, E(T_n) < \log_2(c \cdot n^3) \in O(\log n)$$

11.1. AVL-Bäume von Adelson-Velskii and Landis



Ziel: Zeige, dass die maximale Tiefe eines AVL-Baums mit
n Knoten ($\hat{=}$ n gespeicherten Schlüsseln) $O(\log(n))$ beträgt.

Abbildung 11.1.

11.1.1. AVL-Eigenschaft:

 $|h(T_L) - h(T_R)| \le 1$ muss für jeden Knoten des Baums gelten. \Rightarrow Suchzeit $O(\log(n))$ im worst case.

n(h)=minimale Anzahl von Knoten in AVL-Baum der Tiefe h




Abbildung 11.2.

$$n(h) \ge 1 + n(h-2) + n(h-1) \text{ mit } n(0) = 0 \text{ und } n(1) = 1$$

$$n \ge f(h)^{\mathrm{I}} = \frac{1}{\sqrt{5}} \cdot (\phi^h - \phi^{-h}) \text{ mit}$$

$$\phi = \frac{1 + \sqrt{5}}{2} \approx 1,61 \dots$$

$$\Rightarrow n \ge c \cdot \phi^h$$


$$\Leftrightarrow h \le \log\left(\frac{n}{c}\right)$$

$$\Rightarrow h \in O(\log n)$$


q.e.d.

 $^{^{\}mathrm{I}}f(h)$ meint hierbei die h-te Fibonacci-Zahl

11.2. Rotationen



 $Keys(T_1) < Key(X) < Keys(T_2) < Key(Y) < Keys(T_3)$ balance(Y) = height(Y.left)-height(Y.right)



11.3. Pseudo-Code

```
1
2
   class Node {
3
        int key;
        Node left, right;
4
5
        int height;
6
   }
   int height(Node node) {
9
        if (node = null) return 0;
10
        return height;
11
   }
12
13
   Node rotateRight(Node y) {
14
        Node x = y.left;
15
        Node T2 = x.right;
16
        y.left = T2;
        T_2.right = y;
17
        y.height = 1+max(height(y.left), height(y.right));
18
19
        x.height = 1+max(height(x.left), height(x.right));
20
        return x;
21
   }
22
23
   Node rotateLeft(Node y) {
24
        //analog
25
26
27
   Node insert(Node node, int key) {
28
        if (node == null) return new Node(key);
29
        if (key < node.key)</pre>
30
            node.left = insert(node.left, key);
31
        else
32
            node.right = insert(node.right, key);
33
34
        if (balance(node)>1 && key < node.left.key)</pre>
35
            return rotateRight(node);
        if (balance(node)<-1 && key > node.right.key)
37
            return rotateLeft(node);
38
        if (balance(node)>1 && key > node.left.key) {
39
            node.left = rotateLeft(node.left);
40
            return rotateRight(node);
41
        if (balance(node)<-1 && key < node.right.key) {</pre>
42
43
            node.right = rotateRight(node.right);
44
            return rotateLeft(node);
45
46
        return node;
47 }
```

Anmerkung: Die Laufzeit des Einfügens bleibt in $O(\text{Baumtiefe}) = O(\log n)$. Nur einer der vier Fälle ist notwendig, um die Balance herzustellen.

12.1. (a,b)-Suchbäume

Blattorientierte Speicherung der Elemente

Innere Knoten haben mindestens a und höchstens b Kinder und tragen entsprechende Schlüsselwerte, um die Suche zu leiten.

Beispiel:

$$h = \text{Tiefe} \Rightarrow a^h \leq n \leq b^h \Rightarrow \log_h n \leq h \leq \log_a n$$

12.1.1. Aufspaltung bei Einfügen

12.1.2. Verschmelzen von Knoten beim Löschen

Aufspalte- und Verschmelze-Operationen können sich von der Blattebene bis zur Wurzel kaskadenartig fortpflanzen. Sie bleiben aber auf den Suchpfad begrenzt.

 \Rightarrow Umbaukosten sind beschränkt durch die Baumtiefe $= O(\log n)$

12.2. Amortisierte Analyse

000		
001	Kosten(1) = 1	
010	=2	
011	=1	
100	=3	Kosten der Inkrement-Operation $\hat{=}$ Zahl der Bit-Flips
101	=1	
110	=2	
111	=1	
	$\overline{11}$	
	010 011 100 101 110	$\begin{array}{ccc} 001 & \text{Kosten}(1) = 1 \\ 010 & = 2 \\ 011 & = 1 \\ 100 & = 3 \\ 101 & = 1 \\ 110 & = 2 \\ 111 & = 1 \end{array}$

Naive Analyse $2^k = n$

$$1 \cdot \frac{n}{2} + 2 \cdot \frac{n}{4} + 3 \cdot \frac{n}{8} + \dots + k \cdot \frac{n}{2^k} = \frac{n}{2} \sum_{i=1}^k i(\frac{1}{2})^{i-1} = 2^{k+1} - k - 2 = 2n - k - 2$$

Von 0 bis n im Binärsystem zu zählen kostet $\leq 2n$ Bit-Flips

Sprechweise: amortisierte Kosten einer Inkrement-Operation sind 2 Folge von n-Ops kostet 2n

12.2.1. Bankkonto-Methode

$$\mathrm{Konto}(i+1) = \mathrm{Konto}(i) - \mathrm{Kosten}(i) + \mathrm{Einzahlung}(i)$$

$$\sum_{i=1}^n \mathrm{Kosten}(i) = \mathrm{tats\"{a}chliche} \ \mathrm{Gesamtkosten} = \sum_{i=1}^n (\mathrm{Einzahlung}(i) + \mathrm{Konto}(i-\mathrm{Konto}(i+1))$$

$$= \sum_{i=1}^{n} \operatorname{Einzahlung}(i) + \operatorname{Konto}(1) - \operatorname{Konto}(n+1)$$

000	
001€	Kosten(1) = 1
$01 \in 0$	=2
$01 \in 1 \in$	=1
$1 \in 00$	=3
$1 \in 01 \in$	=1
$1 \in 1 \in 0$	=2
$1 \in 1 \in 1 \in$	=1
	$\overline{11}$

Kontoführungsschema: für Binärzähler

1€pro1in der Binärdarstellung

Jeder Übergang $1 \in \to 0$ kann dann mit dem entsprechenden Euro Betrag auf dieser 1 bezahlt werden. Es gibt pro Inkrement Operation nur einen $0 \to 1$ Übergang

2 € Einzahlung für jede Inc-Operation reichen aus um:

- 1. diesen $0 \to 1$ Übergang zu bezahlen
- 2. die neu entstanden
e $1_{\mbox{\ensuremath{\in}}}$ mit einem Euro zu besparen.

$$GK = 2(2^k - 1) + 0^I - k^{II} = 2n - k - 2$$

 $^{{}^{\}rm I}{\rm Z\ddot{a}hlerstand}(000)$

 $^{^{\}rm II}$ Zählerstand $(111\dots 1)$

Satz: Ausgehend von einem <u>leeren</u> 2-5-Baum betrachten wir die Rebalancierungskosten C (Split- und Fusionsoperationen) für eine Folge von m Einfüge- oder Löschoperationen. Dann gilt: $C \in O(m)$ d.h. Amortisierte Kosten der Split- und Fusionsopeartionen sind konstant.

! Dies bezieht sich nicht auf die Suchkosten, die in $O(\log n)$ liegen.

Beweisidee:

Kontoführung:	1	2	3	4	5	6
Nontolullulig.	2€	1€	0€	0€	1€	2€

regelmäßige Einzahlung: 1€

Durch eine Einfüge- oder Löschoperation steigt oder fällt der Knotengrad des direkt betroffenen Knotens um höchstens $1. \Rightarrow 1 \in$ Einzahlung reicht zur Aufrechterhaltung dieses Sparplanes.

Jetzt Beseitigung der temporären 1- und 6-Knoten:

Ein 6-Knoten nutzt $1 \in$ um seinen Split zu bezahlen. Die beiden neu entstehenden 3-Knoten benötigen kein Kapital. Der Vaterknoten des gesplitteten 6-Knotens benötigt ggf. den zweiten verfügbaren \in . Analoge Betrachtung für Fusion eines temp. 1-Knotens.

13.1. Hashing

 $U \subseteq \mathbb{N}$ z.B. 64-Bit-Integer

n = Zahl dr zu verwaltenden Schlüssel

Hashfunktion h:

$$h: U \rightarrow [0, \ldots, m-1]$$

z.B.
$$k \mapsto k \mod m$$

Einfache Annahme: (einfaches uniformes Hashing)

$$\forall k_i, k_j \in U : Pr(h(k_i) = h(k_j)) = \frac{1}{m}$$

Analyse der Laufzeit zum Einfügen eines neuen Elementes k

- h(k) berechnen $\longrightarrow O(1)$
- Einfügen am Listenanfang in Fach h(k). $\longrightarrow O(1)$

Analyse der Suchzeit für einen Schlüssel k

- $h(k) \longrightarrow O(1)$
- Listenlänge zum Fach h(k) sei $n_{h(k)}$ also beim Durchlauf der kompletten Liste $\longrightarrow O(n_{h(k)})$

$$E(n_{h(k)}) = \frac{n}{m} = \alpha^{\mathrm{I}}$$

Suchzeit(Einfügen) $\in O(1 + \alpha)$

Laufzeit beim Löschen von Schlüssel k

- $\bullet \ h(k) \longrightarrow O(1)$
- Durchlaufen der Liste $\longrightarrow 0(n_{h(k)})$
- \bullet Löschen durch "Pointer-Umbiegen" $\longrightarrow O(1)$

13.1.1. Universelles Hashing

Idee Arbeite nicht mit einer festen Hashfunktionm sondern wähle am Anfang eine zufällige Hashfunktion aus einer Klasse von Hashfunktionen aus.

z.B.

$$h_{a,b}(k) = ((a \cdot k + b) mod p) mod m$$

p sei eine hinreichend große Primzahl $0 < a < p, 0 \leq b < p$

$$\mathcal{H}_{p,m} = \{ h_{a,b}(k) | 0 < a < p, \ 0 \le b < p \}$$

$$|\mathcal{H}_{p,m}| = p(p-1)$$

Definition \mathcal{H} heißt universell $\Leftrightarrow \ \forall \ k,l \in U: \ Pr(h(k)=h(l)) \leq \frac{1}{m}$

^IBelegungsfaktor

Suchzeit

$$\mathcal{X}_{k,l} = \begin{cases} 1 & \text{für } h(k) = h(l) \\ 0 & \text{sonst} \end{cases}$$

$$E(n_{h(k)}) = E\left(\sum_{l \in T, l \neq k}\right) = \sum_{l \in T, l \neq k} E(X_{k,l}) = \sum_{l \in T, l \neq k} Pr(h(k) = h(l)) = \sum_{l \in T, l \neq k} \frac{1}{m} = \frac{n-1}{m} = \alpha$$

Universelles Hashing (Fortsetzung)

Könnte ein boshafter Mitspieler n
 Schlüssel bei gegebener fester Hashfunktion wählen, so würde er sol
che wählen, die auf den gleichen Slot unter gegebener Hashfunktion abgebildet werden. \rightsquigarrow Durchschnittliche Ablaufzeit von O(n)

Idee zufällige Wahl der Hashfunktion aus einer Familie von Funktionen derart, dass die Wahl unabhängig von den zu speichernden Schlüssel ist (universelles Hashing).

14.0.1. Definition

Sei \mathcal{H} eine endliche Menge von Hashfunktionen, welche ein gegebenes Universum U von Schlüsseln auf $\{0,\ldots,m-1\}$ abbildet. Sie heißt universell, wenn für jedes Paar von Schlüsseln $k,l\in U$ $l\neq k$ die Anzahl der Hashfunktionen $h\in\mathcal{H}$ mit h(l)=h(k) höchstens $\frac{|\mathcal{H}|}{m}$. Anders: Für ein zufälliges $h\in\mathcal{H}$ beträgt die Wahrscheinlichkeit, dass zwei unterschiedliche Schlüssel k,l kollidieren nicht mehr als $\frac{1}{m}$ ist.

14.0.2. Beispiel

p Primzahl, so groß, dass alle möglichen Schlüssel $k \in U$ im $0, \ldots, p-1$ liegen. $\mathbb{Z}/p\mathbb{Z}$ bezeichnet den Restklassenring mod p (weil p prim, ist $\mathbb{Z}/p\mathbb{Z}$ ein Körper). $\mathbb{Z}/p\mathbb{Z}^*$ ist die Einheitengruppe.

Annahme: Die Menge der Schlüssel im Universum U ist größer als die Anzahl der Slots in der Hashtabelle. Für $a \in \mathbb{Z}/p\mathbb{Z}^*$ und $b \in \mathbb{Z}/p\mathbb{Z}$ betrachte:

$$h_{a,b}(k) := (a \cdot k + b \mod p) \mod m \quad (*)$$

Damit ergibt sich die Familie

$$\mathbb{Z}/p\mathbb{Z}^* = \{1, \dots, p-1\} \ \mathbb{Z}/p\mathbb{Z} = \{0, \dots, p-1\} \ \mathcal{H}_{p,m} = \{h_{a,b} | a \in \mathbb{Z}/p\mathbb{Z}^*, b \in \mathbb{Z}/p\mathbb{Z}^{(*)} \ |\mathcal{H}| = p(p-1)\}$$

Satz Die in (*) eingeführte Klasse von Hashfunktionen ist universell.

Beweis Seien k, l Schlüssel auf $\mathbb{Z}/p\mathbb{Z}$ mit $k \neq l$

Für $h_{a,b} \in \mathcal{H}_{p,m}$ betrachten wir

$$r = (a \cdot k + b) \mod p$$

$$s = (a \cdot l + b) \mod p$$

Es ist $r \neq s$

Dazu:

$$r - s = a \cdot (k - l) \mod p \quad (*2)$$

Angenommen r - s = 0

$$0 = a \cdot (k - l) \mod p$$
, aber $a \in \mathbb{Z}/p\mathbb{Z}^* \Rightarrow a \neq 0$ und $k \neq l \Rightarrow k - l \neq 0$

Da pprim ist $\mathbb{Z}/p\mathbb{Z}$ ein Körper \Rightarrow kein Nullteiler $\Rightarrow a\cdot (k-l)\neq 0 \Rightarrow r\neq s$

Daher bilden $h_{a,b} \in \mathcal{H}_{p,m}$ unterschiedliche Schlüssel k, l auf unterschiedliche Elemente ab. ("Auf dem level mod p" gibt es keine Kollisionen).

Aus (*2) folgt:

$$(r-s)(k-l)^{-1} = a \mod p$$

$$r - a \cdot k = b \mod p$$
 Bijektion zwischen (k,l) und (a,b)

Daher ist die Wahrscheinlichkeit, dass zwei Schlüssel $h \neq l$ kollidieren, gerade die Wahrscheinlichkeit, dass $r \equiv s \mod m$, falls $r \neq S$ zufällig gewählt (aus $\mathbb{Z}/p\mathbb{Z}$).

Für gegebenes r gibt es unter den übrigen p-1 Werten für s höchstens $\lceil \frac{p-1}{m} \rceil \leq \lceil \frac{p}{m} \rceil - 1$ Möglichkeiten, sodass $s \neq r \mod p$ aber $r = s \mod m$

14.0.3. Abschätzung nach oben

$$\lceil \frac{p}{m} \rceil - 1 \leq \frac{(p+m-1)}{m} - 1 = \frac{p-1}{m}$$
Kollisionsmöglichkeiten

Die Wahrscheinlichkeit, dass r und s kollidieren $\mod m$ Kollisionsmöglichkeiten / Gesamtzahl der Werte

$$= \frac{p-1}{m} \cdot \frac{1}{p-1} = \frac{1}{m}$$

 \Rightarrow Für ein Paar von Schlüsseln $k,l\in\mathbb{Z}/p\mathbb{Z}$ mit $k\neq l$

$$P[h_{a,b}(k) = h_{a,b}(l)] \le \frac{1}{m} \Rightarrow \mathcal{H}_{p,m}$$
 universell!

14.1. Perfektes Hashing

Wichtig Menge der Schlüssel ist im Vorhinein bekannt und ändert sich nicht mehr.

Beispiele reserved words bei Programmiersprachen, Dateinamen auf einer CD

14.1.1. Definition

Eine Hashmethode heißt perfektes Hashing, falls O(1) Speicherzugriffe benötigt werden, um die Suche nach einem Element durchzuführen.

Idee Zweistufiges Hashing mit universellen Hashfunktionen.

- 1. Schritt n Schlüssel, m Slots durch Verwendung der Hashfunktion h, welche aus einer Familie universeller Hashfunktionen stammt.
- 2. Schritt Statt einer Linkedlist im Slot anzulegen, benutzen wir eine kleine zweite Hashtabelle S_j mit Hashfunktion h_j

Bild Schlüssel $k = \{10, 22, 37, 49, 52, 60, 72, 75\}$ Äußere Hashfunktion $h(k) = ((a \cdot b) \mod p) \mod m$

$$a = 3, b = 42, p = 101, m = 9$$

$$h(10) = \underbrace{(3 \cdot 10 + 42 \mod 101)}_{=72} \mod 9 = 0$$

Um zu garantieren, dass keine Kollision auf der zweiten Ebene auftreten, lassen wir die Größe von S_i

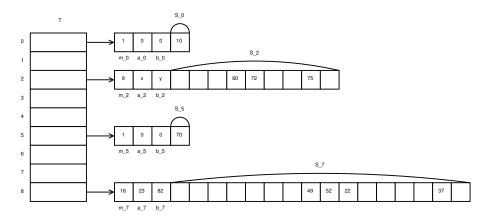


Abbildung 14.1.: Perfekte Hashtabelle

gerade n_j^2 sein $(n_j \neq \#Schlüssel \mapsto jSlot)$.

Wir verwenden für die Hashfunktion der ersten Ebene eine Funktion aus $\mathcal{H}_{p,m}$. Schlüssel die im j-ten Slot werden in der sekundären Hashtabelle S_j der Größe m_j mittels h_j gehasht. $h_j \in \mathcal{H}_{p,m}$

Wir zeigen: 2 Dinge:

- 1. Wie versichern wir, dass die zweite Hashfunktion keine Kollision hat.
- 2. Der erwartete Speicherbedarf ist O(n)

zu 1.

 ${\sf Satz}\;$ Beim Speichern von n Schlüsseln in einer Hashtabelle der Größe $m=n^2$ ist die Wahrscheinlichkeit, dass eine Kollision auftritt $<\frac12$

Beweis: Es gibt $\binom{n}{2}$ mögliche Paare, die kollidieren können. Jedes kollidiert mit der Wahrscheinlichkeit $\leq \frac{1}{m}$, falls $h \in \mathcal{H}$ zufällig gewählt wurde.

Sei X eine zufallsvariable(ZV), X zählt Kollisionen:

Für $m = n^2$ ist die erwartete Zahl der Kollisionen:

$$E[X] = \binom{n}{2} \cdot \frac{1}{m} = \binom{n}{2} \cdot \frac{1}{n^2} = \frac{n!}{2!(n-2)!n^2} = \frac{(n-1)}{2n} \le \frac{1}{2}$$

Anwenden der Markow-Ungleichung (a=1):

$$P[X \ge 1] \le \frac{E[X]}{1} = \frac{1}{2} \Rightarrow$$
 Wahrscheinlichkeit für irgendeine Kollision ist $< \frac{1}{2}$

q.e.d

14.1.2. Nachteil

Für große n ist $m = n^2$ nicht haltbar!

zu 2. Wenn die Größe der primären Hashtabelle m=n ist, dann ist der Platzverbrauch in $O(n) \curvearrowright$ Betrachte Platzverbrauch der sekundären Hashtabellen.

Satz Angenommen wir wollen n Schlüssel in einer Hashtabelle der Größe m=n mit Hashfunktion $h \in \mathcal{H}$. Dann gilt:

$$E\left[\sum_{j=0}^{m-1} n_j^2\right] < 2n$$

Beweis

Betrachte

$$a^{2} = a + 2 \cdot {a \choose n} = a + 2 \cdot \frac{a^{2} - a}{2} \quad (*3)$$

Betrachte

$$E\left[\sum_{j=0}^{m-1} n_j^2\right] \stackrel{(*3)}{=} E\left[\sum_{j=0}^{m-1} \left(n_j + 2\binom{n_j}{2}\right)\right]$$

$$\stackrel{lini.desEW}{=} E \left[\sum_{j=0}^{m-1} n_j \right] + 2E \left[\sum_{j=0}^{m-1} \binom{n_j}{2} \right] = n + 2E \left[\sum_{j=0}^{m-1} \binom{n_j}{2} \right] \# \text{ der Kollisionen}$$

Da unsere Hashfunktion universell ist, ist die erwartete Zahl dieser Paare:

$$\binom{n}{2}\frac{1}{m}=\frac{n(n-1)}{2m}=\frac{n-1}{2},$$
da $m=n$

Somit

$$E\left[\sum_{j=0}^{m-1} n_j^2\right] \le n + 2\frac{n-1}{2} = 2n - 1 < 2n$$

Korollar Speichern wir n Schlüssel in einer Hashtabelle der Größe m=n mit einer zufälligen universellen Hashfunktion und setzen die Größe der Hashtabellen der zweiten Ebene auf $m_j=n_j^2$ für j=0, m=1, so ist der Platzverbrauch des perfekten Hashings weniger als 2n. Die Wahrscheinlichkeit, dass der Platzverbrauch der zweiten Hashtabellen $\geq 4n$ ist, ist $\leq \frac{1}{2}$ ohne Beweis.

Bei n Elementen sollte die Hashtabelle $m=n^2$ groß sein. Für die universellen Hashfunktionen

$$\mathcal{H}_{p,m} = \{h_{a,b}(k) = (a \cdot k + b) \mod p \mod m | 0 < a < p, \ 0 \le b < p\}$$

 $\binom{n}{1}$ Schlüsselpaare (k,l)mit $k\neq l$

$$E(\# \text{Kollisionen}) \leq \binom{n}{2} \cdot \frac{1}{m}^{\text{I}} = \frac{n(n-1)}{2} \cdot \frac{1}{n^2} \leq \frac{1}{2}$$

Idee Zweistufiges Verfahren:

 \bullet primäre Hashfunktion für Tabelle der Größe m=n

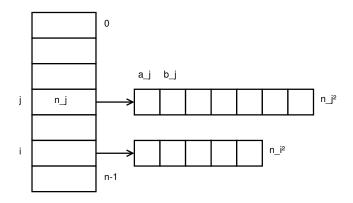


Abbildung 15.1.: Perfektes Hashing

 $^{^{\}rm I}$ Universalität von ${\mathcal H}$

Teil II. Graphen-Algorithmen

15.0.1. Einführung

 $G = (V, E) \quad V \text{ vertices, } E \text{ edges} \quad E \subseteq V \times V$

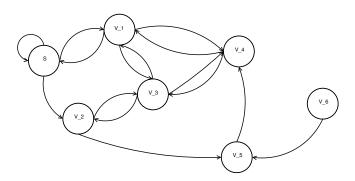


Abbildung 15.2.: Gerichteter Graph

Planare Graphen können ohne Überkreuzung der Kanten in die Ebene eingebettet werden.

Eulerische Polyederformel

$$|V| + |F| = |E| + 2$$

$$8+6=12+2$$

Es gilt:

$$2 \cdot |E| \ge 3 \cdot |F|$$

#gerichtete Kanten =
$$2 \cdot |E| = \sum_{i=1}^{|F|} \# \text{Kanten}(f_i)^{\text{II}} \ge 3 \cdot |F|$$

$$|F| \leq \frac{2}{3}|E|, \quad |V| + |F| = |E| + 2 \leq |V| + \frac{2}{3}|E| \Rightarrow \frac{1}{3}|E| + 2 \leq |V|$$

$$\Rightarrow |E| \le 3 \cdot |V| - 6$$

Abbildung 15.4.: Placeholder

Abbildung 15.3.: Würfel

II Jedes f_i hat mindestens 3 Kanten




Abbildung 15.5.: Beispiel

Adjazenzmatrix

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	
0	1	0	1	0	0	1	0	0	1	1	0	0	0	0]
1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	
2	1	1	1	1	0	0	0	0	0	0	0	0	0	0	
3	0	0	0	1	0	0	1	0	0	0	0	0	0	0	
4	0	1	0	0	1	0	0	1	0	0	0	0	0	0	
5	0	0	1	0	0	1	1	0	0	0	0	0	0	0	
6	0	0	0	0	0	0	1	0	0	1	1	0	0	0	= A
7	0	1	0	0	0	0	0	1	0	0	0	0	0	0	
8	0	0	1	0	1	0	0	1	1	0	0	0	0	0	
9	0	0	0	0	0	1	0	0	0	1	1	1	0	1	
10	0	0	0	0	0	0	0	0	0	0	1	0	0	1	
11	1	0	0	0	0	0	0	0	0	0	0	1	1	0	
12	0	0	0	0	0	0	0	1	1	0	0	0	1	0	
13	0	0	0	0	0	0	0	0	0	0	0	1	1	1	

$$a \in B^{|V| \times |V|}$$

falls G ungerichtet $\Rightarrow A = A^T$

Adjazenzlisten Repräsentation




Abbildung 15.6.: Adjazenzliste

Platzbedarf

$$\mathcal{O}(|V| + |E|) = \mathcal{O}\left(|V| + \sum_{i=0}^{|V|-1} \text{outdeg}(v_i)\right)$$




Abbildung 15.7.: indeg und outdeg

15.0.2. BFS (Breadth-First Search) Breitensuche

```
forall ( v in V\{S}) {
1
2
    col[v]=white;
                      // Farbe weiß = unbekannt, grau = bekannt, schwarz = vollkommen bekannt
3
    d[v] = infinity; // Distanz
    pi[v] = NULL;
                      // pi ist Vorgänger
4
5
  }
6
  col[s] = grey;
                       // s ist Startknoten
  d[s] = 0;
8 pi[s] = NULL;
         Queue
                      vs
                               Stack
        Schlange
                               Stapel
                                 "
        empty()
                                 ,,
         push()
         pop()
         FIFO
                               FILO
   First-In-First-Out
                          First-In-First-Out
```

```
Queue Q;
   Q.push(s);
3
   while(!Q.empty()) {
4
      u = Q.pop();
5
      forall( (u,v) in E) {
6
        if (col[v] == white) {
7
          col[v] == grey;
8
          d[v] = d[u] + 1;
9
          pi[v] = u;
10
          Q.push(v);
11
12
13
      col[u] = black;
14
   }
```

Laufzeit

$$O(|V| + |E|)$$

Begründung: Jeder von s aus erreichbare Knoten wird nur einmal in die Queue aufgenommen und auch ihr entfernt. Für jeden Knoten muss nur einmal seine Adjazenzliste durchlaufen werden.

$$\Rightarrow \mathcal{O}\left(|V| + \sum_{v \in V} \text{outdeg}(v)\right)$$




Abbildung 15.8.: Grafik zum Beispielcode




Abbildung 16.1.: Beispiel

Definition: Länge kürzesten Weges

 $\delta(s,v)=$ Länge eines kürzesten Weges vom Startknoten s zum Knoten v. Setze $\delta(s,v)=\infty$, falls v nicht erreichbar von s aus.

Satz: Richtigkeit des Algorithmus

Nach Ablauf von BFS^I gilt

$$\forall v \in V: \ d[v] = \delta(s, v)$$

Lemma 1: Dreiecksungleichung für kürzeste Wege




Abbildung 16.2.

Lemma 2

Zu jedem Zeitpunkt im Verlauf von BFS gilt:

$$\forall v \in V : d[v] \ge \delta(s, v)$$

Beweis (induktiv über Zahl der Operationen, die d-Wert verändern)

Induktions-Anfang

$$d[s] = 0 \sqrt{}$$

Induktions-Schritt Knoten v wird von u aus neu entdeckt

$$d[u] \ge \delta(s, u)$$

$$d[v] = d[u] + 1 \ge \delta(s, u) + 1 \stackrel{D.U.}{\ge} \delta(s, v)$$

Lemma 3

Sei $Q = (v_1, v_2, \dots, v_k)$ eine Queue, dann gilt stets:

$$d[v_1] \le d[v_2] \le \ldots \le d[v_k] \le d[v_1] + 1$$

 $^{^{\}rm I}{\rm Breiten such e}$

Beweis (induktiv über die Zahl der push- und pop-Operationen)

Induktions-Anfang

$$d[s] = 0\sqrt{}$$

Induktions-Schritt

pop

$$d[v_1] \le d[v_2] \le \dots \le d[v_k] \le d[v_1] + 1 \le d[v_2] + 1$$

push

$$d[u] = d[v_1] \le d[v_2] \le \ldots \le d[v_k] \le d[u] + 1$$

Beachte Kante (u, v) v ist weiß

 $v = v_{k+1}$ wird gepushed

$$d[v_{k+1}] = d[v_1] + 1$$

Zustand von Q nach push

$$d[v_2 \le d[v_3] \le \ldots \le d[v_k] \le d[v_1] + 1 = d[v_{k+1}] \ \ \checkmark$$

Satz: Richtigkeit des Algorithmus

Nach Ablauf von BFS^{II} gilt

$$\forall v \in V : d[v] = \delta(s, v)$$

Beweis durch Widerspruch

Sei $v \in V$, so dass $d[v] \neq \delta(s, v)$ am Ende des Algorithmus $\stackrel{Lemma2}{\Longrightarrow} d[v] > \delta(s, V)$

Sei v so gewählt, dass es der erste knoten ist mit der Eigenschaft, dass sein d-Wert flasch gesetzt wird. d.h. Alle d-Werte bis zu diesem Zeitpunkt sind korrekt.

Sei $s \mapsto u' \to v$ ein kürzester Weg s ui v

Betrachte die Situation bei Bearbeitung von u':

1. Fall v ist in diesem Moment schwarz.

$$d[v] > \delta(s, v) = \delta(s; u') + 1 >$$
^{III} $d[v]$ f

2. Fall v ist in diesem Moment weiß.

$$d[v] > \delta(s, u') + 1 = d[u'] + 1 = {}^{\text{IV}}d[v]$$

II Breitensuche


 $^{^{\}mathrm{III}}v$ vor u' aus Q entfernt und Lemma 3.

 $^{^{\}mathrm{IV}}$ wegen Wahl von v;d-Wert von u'muss also korrekt sein

3. Fall v ist grau.

$$d[v] > \delta(s, u') + 1 = d[u'] + 1 \ge d[u] + 1 = d[v]$$

 $d[u] \le d[u']$, weil u vor u' aus Q entfernt $\mbox{\em 4}$



q.e.d.

Abbildung 16.3.

16.1. Kürzeste Wege Algorithmen

16.1.1. Dijkstra-Algorithmus

$$G = (V, E)$$
 $w : E \to \mathbb{R}_0^+$

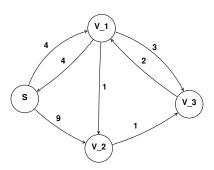


Abbildung 16.4.

Sei
$$p = (s = v_0, v_1, v_2, \dots, v_k)$$



Abbildung 16.5.

$$w(p) = \sum_{i=0}^{k-1} w(v_i, v_{i+1}) = \delta(s, v_k)$$




Abbildung 16.6.

$$\delta(s, v) \le \delta(s, U) + w(u, v)$$

Betrachte Algorithmen zur kürzesten Wege Berechnung, die Distanzwerte nur mit Hilfe dieser relax-Funktion verändern, dann gilt:

$$d[v] \ge \delta(s, v) \quad \forall v \in V$$

Beweis

$$d[v] = d[u] + w(u, v) \stackrel{I.A.}{\geq} \delta(s, u) + w(u, v) \geq \delta(s, v)$$

Induktion über Zahl der reflex-Aufrufe

Dijkstra Algorithmus (Fortsetzung)

$$G = (V, E) \quad w : E \to \mathbb{R}^{\geq 0}$$

```
forall (v \in V) {
2
      d[v] = \infty;
3
      \Pi[v] = NULL;
4
   }
5 d[s] = 0;
6 S = \emptyset;
7
    PriorityQueue PQ;
8
    \quad \quad \text{forall } (v \in V)
9
      PQ.insert((d[v],v));
10
    while(!PQ.empty()) {
11
      u = PQ.deleteMin();
12
      forall( (u,v) \in E) {
         if ( d[v] > d[u] + w(u,v)) {
13
           d[v] = d[u] + w(u,v);
14
           \Pi[v] = u;
15
16
           PQ.decreaseKey((d[v],v));
17
18
19
      S = S \cup \{u\};
20
```

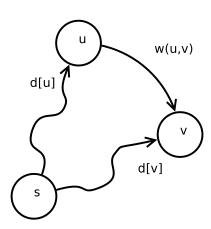


Abbildung 17.1.

Satz: Der Dijkstra Algorithmus berechnet alle d-Werte, so dass nach Ablauf des Algo $\forall v \in V$ gilt: $d[v] = \delta(s, v)$.

Beweis:

Annahme:

$$\exists v \in V: \ d[v] \neq \delta(s, v)$$

$$\stackrel{LemmaRelax}{\Longrightarrow} d[v] > \delta(s, v)$$

Sei v so gewählt, das v der erste Knoten mit der Eigenschaft ist, der mit deleteMin der PQ entnommen wird und nach Relaxation aller von ihm ausgehenden Kanten der Menge S hinzugefügt wird.

Betrachte einen kürzesten Weg $s \leadsto v$

$$d[v] > \delta(s, v) \ge {}^{\mathrm{I}}\delta(s, y) = d[y] = {}^{\mathrm{II}}d[x] + w(x, y) = d[y] \ge {}^{\mathrm{III}}d[v]$$
 4

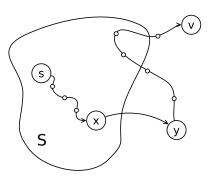


Abbildung 17.2.: Skizze

17.0.1. Vorläufige Laufzeitanalyse von Dijkstra

PQ.
insert x |V|
PQ.
empty x |V|
PQ.deleteMin x |V|
PQ.decreaseKey x |E|
Mit balanciertem Suchbaum oder mit binärem Heap (siehe Heapsort)

können diese Opeartionen alle in Zeit $O(\log |V|)$ realisiert werden.

 \Rightarrow Gesamtlaufzeit: $\mathcal{O}((|V| + |E|) \log |V|)$

Wir werden später zeigen, dass Laufzeit $\mathcal{O}(|V| \log |V| + |E|)$ möglich ist.

17.1. Bellman-Ford-Algorithmus

$$G = (V, E) \ w : E \to \mathbb{R}$$

Voraussetzung G enthält keine negativen Zyklen

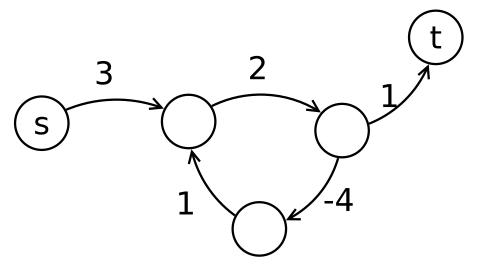


Abbildung 17.3.: Ein verbotener, negativer Zyklus

^Iweil Kantengewichte nicht negativ sein dürfen

 $^{^{\}rm II}$ x wurde schon zu S hinzugefügt, hat also Korrekten d-Wert $d[x] = \delta(s,x)$

 $^{^{\}rm III}$ weil v
 vor y aus der PQ entnommen wird.

17.1.1. Pseudocode

```
1
   forall(v \in V) {
2
      d[v] = \infty;
3
      \Pi[v] = NULL;
4
   d[s] = 0;
   for(i = 1; i < |V|; i++ )</pre>
      forall((u,v) \in E)
        if(d[v] > d[u] + w(u,v)) {
8
9
          d[v] = d[u] + w(u,v);
10
          \Pi[v] = u;
11
```

17.1.2. Laufzeit: Bellman-Ford

 $O(|V| \cdot |E|)$

17.1.3. Korrektheitsbeweis: Bellman-Ford

Invariante: Nach den i-ten Schleifendurchlauf sind alle Kürzesten Wege korrekt berechnet, die $\leq i$ Kanten benutzen.

Beweis: Induktion über i

Induktionsanfang

i = 0 $d[s] = 0 = \delta(s, s)$, da keine negativen Zyklen vorliegen.

17.1.4. Induktionsschritt: $i \rightarrow i+1$

Betrachte kürzesten Weg mit i + 1 Kanten:

$$s = v_0 \rightarrow v_1 \rightarrow v_2 \rightarrow \ldots \rightarrow v_i \rightarrow v_{i+1}$$

Aufgrund der Induktionsannahme^{IV} gilt: $d[v_i] = \delta(s, v_i)$, weil $s = v_0 \to v_1 \to \ldots \to v_i$ ein kürzester Weg $s \leadsto v_i$ mit i Kanten ist. Da alle Kanten in der inneren Schleife einmal relaxiert werden, trifft dies insbesondere auf die Kante (v_i, v_{i+1}) zu:

$$d[v_{i+1}] = d[v_i] + w(v_i, v_{i+1}) = \delta(s, v_i) + w(v_i, v_{i+1}) = \delta(s, v_{i+1})$$

Frage: Warum folgt aus der Gültigkeit dieser Invariante die Korrektheit des Algo?

Antwort Alle kürzesten Wege benutzen höchstens |V|-1 Kanten, ansonsten hätten sie einen Zyklus mit Gewicht ≥ 0 , den man auch weglassen kann.

```
//Erkennung der Existenz negativer Zyklen
forall((u,v) ∈ E)
if(d[v] > d[u] + w(u,v))
negativer Zyklus
```

 $^{^{\}rm IV}{\rm Die}$ Invariante

18.1. All-Pairs-Shortest Path Algorithmen

Distanz
matrix D für einen Graphen $G=(V,E)\ V=v_1,v_2,\ldots,v_n,\ w:E\mapsto\mathbb{R}$

$$d_{ij} = \begin{cases} 0 & \text{für } i = j \\ w(v_i, v_j) & \text{für } (v_i, v_j) \in E \\ \infty & \text{sonst} \end{cases}$$

$$D = (d_{ij})_{\substack{i=1,\dots,n\\j=1,\dots,n}} \in \mathbb{R}^{n \times n}$$

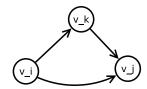


Abbildung 18.1.: Grafik

$$d_{ij}^{(2)} = \min(d_i^{(1)}j, \ \min(d_{ik}^{(1)} + d_k^{(1)}j))$$

$$k=1,\dots,n$$

$$D^{(2)} = D^{(1)} \circ D^{(1)} = \min(d_{ik}^{(1)} + d_k^{(1)}j)$$

Vergleich zu Matrixmultiplikation

$$C = A \circ B$$
 , mit $A, B \in \mathbb{R}^{n \times n}$

$$C_{ij} = \sum_{k=1}^{n} a_{ik} \cdot b_{kj}$$

im Ring $(\mathbb{R}, +, \cdot)$

$$C_{ij} = (A_{ik} + B_{kj})$$

Kommutativgesetz

$$\min(\min(a, b), c) = \min(a, b, c)$$

im "Ring" $(\mathbb{R}, \min, +)$

Distributivgesetz

$$a + \min(b, c) = \min(a + b, a + c)$$

^Ider keiner ist

Assoziativgesetz

$$A \circ (B \circ C) = (A \circ B) \circ C$$

Ziel: $D^{(n)} = D^{(1)} \circ D^{(1)} \circ \dots \circ D^{(1)}$

Es gilt: $D^{(n)} = D^{(n+m)}$ für $m \ge 1$

18.1.1. Laufzeit zur Berechnung von $D^{(n)}$

Naiv: $O(n^4)$

$$D^{(2)} = D^{(1)} \circ D^{(1)}$$

$$D^{(4)} = D^{(2)} \circ D^{(2)}$$

$$D^{(8)} = D^{(4)} \circ D^{(4)}$$

:

$$D^{(2^i)} = D^{(2^{i-1})} \circ D^{(2^{i-1})}$$

Schrittzahl i so wählen, dass $2^i \ge n$

sukzessives Quadrieren: $O(n^3 \log n)$

18.2. Floyd-Warshall-Algorithmus

```
for ( k = 1; k ≤ n; k++)
for( i = 1; i ≤ n; i++)
for ( j = 1; j ≤ n; j++)
d[i][j] = min(d[i][j], d[i][k]+d[k][j])
```

Laufzeit $O(n^3)$

18.2.1. Korrektheitsbeweis:

Invariante Nach dem k-ten Schleifendurchlauf entspricht d_{ij} der Weglänge eines kürzesten Weges p von v_i nach v_j , wobei nur Zwischenknoten erlaubt sind, mit Index $\leq k$

$$p: v_i \to v_{l_1} \to v_{l_2} \to \ldots \to v_{l_m} \to v_j$$

d.h.
$$1 \le l_1, l_2, \dots, l_m \le k$$

 $[\]overline{\ ^{\text{II}}\text{In der Potenz}}$ stehen die Anzahl der betrachteten Kanten.
n entspricht allen Kanten

18.2.2. Beweis der Invariante durch Induktion nach k

k=0: Nach der Initialisierung von D, also vor dem 1. Schleifendurchlauf, gilt obige Invariante.

 $k-1 \rightarrow k$:

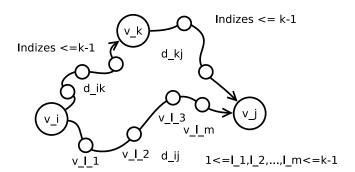


Abbildung 18.2.: Beweis der invariante

Durch die Operation $d_{ij} = \min(d_{ij}, d_{ik} + d_{kj})$ wird die Invariante sichergestellt.

18.3. Naive Lösung des All-Pairs Problems durch |V|-malige Anwendung von Bellman-Ford oder Dijksta-Algorithmus

 $\textbf{Bellman-Ford} \ \ \mathfrak{O}(|V|\cdot |V|\cdot |E|) = \mathfrak{O}(|V|^2\cdot |E|)$

Dijksra $\mathcal{O}(|V| \cdot (|V| \cdot \log |V| + |E|)) = \mathcal{O}(|V| \cdot |E| + |V|^2 \cdot \log |V|)$

18.4. Johnson-Algorithmus

Idee: Neugewichtung der Kanten, so dass keine negativen Kantengewichte mehr vorhanden sind. Anschließend |V|-mal Dijkstra-Algorithmus ausführen.

Naiver Ansatz




Abbildung 18.3.: Naiver Ansatz, kürzester Weg wird zerstört

Neuer Ansatz

$$w'(u, v) = \operatorname{pot}^{\operatorname{III}}(u) - \operatorname{pot}(v) + w(u, v) \ge 0$$

Mit dieser Neugewichtung gilt, dass kürzeste Wege bzgl. w den kürzesten Wegen bzgl. w' entsprechen.

$$p: s = v_0 \to v_1 \to v_2 \to \dots v_i \to v_{i+1} \to \dots v_k = t$$

$$w'(p) = \sum_{i=0}^{k-1} w'(v_i, v_{i+1}) = \sum_{i=0}^{k-1} \left[pot(v_i) - 1pot(v_{i+1}) + w(v_i, v_{i+1}) \right]$$

$$\stackrel{Teleskopsumme}{=} pot(v_0) - pot(v_k) + \sum_{i=1}^{k-1} w(v_i, v_{i+1}) = pot(s) - pot(t) + w(p)$$

d.h. Alle kürzesten Wege $s \leadsto t$ unterscheiden sich bzgl. w' im Vergleich zu w nur um eine feste additive Konstante pot(s) - pot(t)

$$pot(u) - pot(v) + w(u, v) \ge 0$$
$$pot(v) \le pot(u) + w(u, v)^{IV}$$
$$pot(v) = \delta(z, v)$$
$$G' = (V', E') \quad V' = V \cup z, E' = E \cup (z, v) | v \in V \quad \text{mit } w'(z, v) = 0$$




Abbildung 18.4.: Die blau makierten Kanten haben die Länge 0

- \bullet Löse single-source-shortest-Path Problem in G' mit z als Startknoten
- setze $pot(v) = \delta_{G'}(z, v)^{V}$
- Neugewichtung
- \bullet |V|-mal Djikstra

18.4.1. Laufzeit des Johnson-Algorithmus

$$O(|V| \cdot |E| + |V| \cdot (|V| \cdot \log |V| + |E|)) = O(|V| \cdot |E| + |V|^2 \cdot |V|)$$

III Potential funktion

^{IV}Dreiecksungleichung

Vberechnet mit Bellman-Ford